Aggiornamento della proposta di progetto

Estensione frequentista, bayesiana e machine learning di un'analisi LHCb Open Data sui decadimenti a tre corpi dei mesoni B

Giacomo Moretti Marco

14 settembre 2026

Nota. Questo documento aggiorna la proposta originale (`Proposta_progetto_LHCb_OpenData_Giacomo_Moretti.pdf`) recependo due cambiamenti: il progetto è ora svolto in coppia, e sono state concordate alcune estensioni metodologiche aggiuntive emerse in fase di revisione. La research question e l'impianto generale restano quelli della proposta originale.

1 Research question (invariata)

In che misura fit frequentisti di likelihood, inferenza bayesiana e selezioni assistite da machine learning producono stime consistenti e controllate dell'asimmetria grezza A_{raw} nei decadimenti $B^{\pm} \to h^{\pm}h^{+}h^{-}$ di LHCb Open Data?

2 Composizione del gruppo e responsabilità

Membro	**Responsabilità principale**
Marco	Completamento del notebook ufficiale (baseline) ed estensione frequentista: fit di massa signal + background, fit simultaneo parametrizzato su A, profile likelihood e confidence interval.
Giacomo Moretti	Estensione bayesiana: definizione di prior/likelihood/posterior sullo stesso modello fisico, campionamento MCMC, credible interval, confronto con i risultati frequentisti.
Entrambi	Phase-space MC per gli altri canali, modulo ML, confronto finale delle stime di A_{raw}, stesura del report.

Table 1: Divisione dei compiti concordata.

Nota operativa. Perché i risultati dei due filoni (frequentista e bayesiano) restino confrontabili a fine progetto, è importante che Marco e Giacomo condividano fin da subito lo stesso modulo di lettura dati e preselezione (stesse variabili, stessi tagli PID/muon veto) e la stessa parametrizzazione del modello di massa $f(m) = N_s\, S(m;\theta_s) + N_b\, B(m;\theta_b)$: la parte bayesiana riusa il modello fisico della parte frequentista, cambia solo il trattamento dei parametri.

3 Pipeline operativa aggiornata

#	Blocco	Output principale	Responsabile
0	Baseline notebook	Lettura dati, ricostruzione massa, selezione KKK, A_{raw} globale, Dalitz plot	Marco
1	Fit frequentista	Modello massa signal + background, fitted yields	Marco
2	Profile likelihood	A_{raw} da fit simultaneo, confidence interval	Marco
3	Analisi bayesiana	Prior, posterior, MCMC, credible interval	Giacomo
4	Phase-space MC	Campioni truth-level KKK, K$\pi\pi$, πKK, $\pi\pi\pi$	Entrambi
5	Modulo ML	Weak label da sidebands, classificatori, ROC, stabilità di A_{raw}	Entrambi
6	Confronto finale	Tabella A_{raw}: conteggio, fit, bayes, ML-assisted	Entrambi

Table 2: Pipeline della proposta originale con responsabile assegnato per blocco.

4 Estensioni metodologiche aggiuntive

Rispetto alla proposta originale, sono state concordate le seguenti aggiunte, a basso costo implementativo e coerenti con gli argomenti del corso:

1. **Bayes factor per il test $A = 0$ vs A libero.** La proposta originale usa MCMC/credible interval ma non i Bayes factor, argomento esplicito di Week 4. Aggiungere questo test dà un secondo confronto di ipotesi bayesiano da affiancare al p-value frequentista. *(Sezione bayesiana, Giacomo)*

2. **Cross-check Magnet Up vs Magnet Down.** I due file `B2HHH_MagnetUp.root` e `B2HHH_MagnetDown.root` permettono di calcolare A_{raw} separatamente per le due polarità del magnete e verificarne la consistenza: la pratica standard LHCb cancella parzialmente l'asimmetria di rivelazione sommando le due polarità. Check a costo quasi nullo, dati già disponibili. *(Sistematiche)*

3. **Confronto con i valori pubblicati.** Il paper di riferimento (arXiv:2403.19921, LHCb Collaboration) riporta gli A_{CP} misurati per gli stessi quattro canali. Il confronto qualitativo tra il nostro A_{raw} e i valori pubblicati (già corretti per efficienza e asimmetria di produzione) illustra concretamente perché $A_{raw} \neq A_{CP}$, punto già segnalato come rischio nella proposta originale. *(Discussione nel report)*

4. **Toy-MC coverage check.** Generare pseudo-dataset con phase-space MC iniettando un valore noto di A, ripetere fit e posterior su molte repliche, verificare la copertura reale dei confidence/credible interval. Rende esplicito e quantitativo quanto già previsto genericamente nella sezione "toy studies" della proposta originale. *(Validazione, entrambi)*

5. **Cross-validation e regolarizzazione nel modulo ML.** Split train/validation/test esplicito e tuning via cross-validation per BDT/FFNN, con eventuale analisi PCA/correlazione esplorativa sulle feature cinematiche prima della classificazione. Introduce minimamente Lecture 10, non coperta altrimenti dal progetto. *(Modulo ML)*

6. **(Opzionale) ML-assisted Dalitz regions.** Se il tempo lo permette: usare un classificatore o un clustering per definire regioni del Dalitz plot in modo adattivo, invece del binning fisso,

e verificare se emergono zone di asimmetria non catturate dal binning manuale. Risponde alla domanda 13 già posta al docente nella proposta originale. *(Stretch goal)*

5 Toolchain concordato

Per coerenza con le esercitazioni del corso (verificato sui notebook di `Statistics_exe/`):

- Fit MLE / frequentisti: **iminuit** (`Minuit`, `iminuit.cost.UnbinnedNLL`)
- MCMC bayesiano: **emcee** + **corner** per i corner plot
- Machine learning classico: **scikit-learn**
- Reti neurali: **Keras/TensorFlow**

6 Prossimi passi immediati

- **Marco:** eseguire `LHCb_Open_Data_Project.ipynb` end-to-end per ottenere la baseline (lettura dati, massa invariante, A_{raw} da conteggio, Dalitz plot), poi costruire il modello di massa signal+background con iminuit.
- **Giacomo:** definire il modello statistico bayesiano (parametri $\theta = (N_s, N_b, A, \mu, \sigma, \lambda_{bkg})$ e prior) sullo stesso modello di massa concordato con Marco, e preparare il setup emcee.