Proposta di progetto

Estensione frequentista, bayesiana e machine learning di un'analisi LHCb Open Data sui decadimenti a tre corpi dei mesoni B

Giacomo Moretti Marco Belotti

14 settembre 2026

Idea centrale. Partire dal notebook ufficiale CERN Open Data sulle differenze materia-antimateria nei decadimenti $B^{\pm} \to h^{\pm}h^{+}h^{-}$, riprodurre l'analisi guidata, e trasformarla in un progetto metodologico completo: fit frequentista della massa, stima di A_{raw} con profile likelihood, riformulazione bayesiana con MCMC e modulo ML per signal/background e studi di stabilità. Proposta operativa per progetto di gruppo basato sul corso di Statistics & Machine Learning applicato alla fisica delle alte energie.

Dataset reale LHCb ROOT/TTree · CP asymmetry · Dalitz plot · MLE/Profile likelihood · MCMC · ML selection

1 Composizione del gruppo e responsabilità

Il progetto è svolto in coppia. La divisione dei compiti concordata è la seguente:

Membro	**Responsabilità principale**
Marco Belotti	Completamento del notebook ufficiale (baseline) ed estensione frequentista: fit di massa signal + background, fit simultaneo parametrizzato su A, profile likelihood e confidence interval.
Giacomo Moretti	Estensione bayesiana: definizione di prior/likelihood/posterior sullo stesso modello fisico, campionamento MCMC, credible interval, confronto con i risultati frequentisti.
Entrambi	Toy-MC coverage check, modulo ML, confronto finale delle stime di A_{raw}, stesura del report.

Table 1: Divisione dei compiti.

Nota operativa. Perché i risultati dei due filoni (frequentista e bayesiano) restino confrontabili, Marco e Giacomo condividono fin da subito lo stesso modulo di lettura dati e preselezione (stesse variabili, stessi tagli PID/muon veto) e la stessa parametrizzazione del modello di massa $f(m) = N_s\, S(m;\theta_s) + N_b\, B(m;\theta_b)$: la parte bayesiana riusa il modello fisico della parte frequentista, cambia solo il trattamento dei parametri. Questo permette di lavorare in parallelo senza dover attendere il completamento reciproco.

2 Contesto e motivazione

Il progetto si colloca nell'ambito dell'analisi statistica dei decadimenti adronici a tre corpi dei mesoni B carichi, con particolare attenzione alle differenze fra materia e antimateria. Nei decadimenti $B^{\pm} \to h^{\pm}h^{+}h^{-}$ lo spazio delle fasi a tre corpi permette non solo una misura globale dell'asimmetria, ma anche uno studio locale tramite Dalitz plot, dove eventuali differenze possono essere concentrate in regioni cinematiche specifiche.

L'obiettivo non è produrre una misura competitiva con una pubblicazione LHCb completa, ma usare dati reali e un notebook pubblico validato come base per un progetto didattico avanzato: riproducibile, statisticamente rigoroso e coerente con il programma del corso.

Research question

In che misura fit frequentisti di likelihood, inferenza bayesiana e selezioni assistite da machine learning producono stime consistenti e controllate dell'asimmetria grezza A_{raw} nei decadimenti $B^{\pm} \to h^{\pm}h^{+}h^{-}$ di LHCb Open Data?

3 Argomenti del corso utilizzati

Il progetto è disegnato per usare in modo esplicito i blocchi principali del corso di Statistics & Machine Learning applicato alla HEP: inferenza frequentista, likelihood, covariance, profile likelihood, inferenza bayesiana, MCMC, supervised learning, tree-based methods, neural networks e uncertainty estimation.

Modulo del corso	**Strumento**	**Uso nel progetto**
Frequentist inference	Hypothesis testing, p-value, MLE	Fit di massa, stima di yield e test $A_{raw} = 0$
Covariance / confidence regions	Hessian, Wilks, profile likelihood	Intervalli di confidenza e profiling sui nuisance
Bayesian inference	Prior, posterior, MCMC, credible intervals, **Bayes factor**	Posterior su yield e A_{raw}; test $A = 0$ vs A libero
Statistical learning	Classification, bias-variance, regularization	ML signal/background con sidebands, cross-validation
Tree/NN methods	BDT, random forest, FFNN	Confronto fra baseline classiche e rete neurale
Uncertainty in ML	Bootstrap, ensemble, calibration	Stabilità dell'asimmetria al variare del modello e della soglia ML

Table 2: Mappatura tra argomenti del corso e uso nel progetto.

4 Dataset, notebook di partenza e software

Dataset principale

Il dataset principale è il record CERN Open Data "Matter Antimatter Differences - B meson decays to three hadrons". I dati sono stati raccolti da LHCb nel 2011 a $\sqrt{s} = 7$ TeV, ricostruiti con il software dell'esperimento, selezionati dal trigger e da una selezione offline, e contengono

candidati per decadimenti di un mesone B carico in tre particelle cariche. I file sono ROOT TTree e includono solo le variabili ricostruite più importanti. Il record riporta circa 8.55 milioni di eventi, 3 file e 1.0 GiB totali.

Lo stesso record include anche una simulazione semplificata del decadimento $B^{\pm} \to K^{\pm}K^{+}K^{-}$, non passata attraverso una simulazione della risposta del detector: utile come riferimento cinematico phase-space, ma non da trattare come full simulation detector-level.

Notebook di partenza

Il notebook ufficiale "Matter Antimatter Differences - Project Notebook" fornisce un'analisi guidata: simulazione, ricostruzione della massa invariante, dati reali, preselezione, asimmetria globale, Dalitz plot, asimmetrie locali e una sezione finale di possibili estensioni ("Further analyses"), punto naturale da cui parte il presente progetto.

Ambiente tecnico

- Python/Jupyter come ambiente principale; `uproot` per la lettura dei file ROOT/TTree (niente installazione ROOT necessaria).
- `numpy`, `pandas`, `scipy`, `matplotlib` per analisi e visualizzazione.
- **iminuit** (`Minuit`, `iminuit.cost.UnbinnedNLL`) per i fit frequentisti.
- **emcee** + **corner** per il campionamento MCMC bayesiano e i corner plot.
- **scikit-learn** per il machine learning classico; **Keras/TensorFlow** per le reti neurali.

Questo toolchain è stato scelto per coerenza con le esercitazioni del corso (verificato sui notebook di `Statistics_exe/`), non solo per convenienza tecnica.

5 Obiettivi scientifici e metodologici

1. Riprodurre e completare il notebook ufficiale LHCb Open Data, mantenendo piena tracciabilità rispetto alla baseline.
2. Passare da una stima per conteggio di A_{raw} a una stima da fit di massa con segnale e fondo.
3. Implementare una stima frequentista con MLE, covariance matrix, profile likelihood e confidence interval.
4. Riformulare lo stesso problema in modo bayesiano, con posterior su yield e asimmetria e credible intervals.
5. Applicare ML in modo controllato per separazione signal/background tramite sidebands, senza usare la massa come feature di input.
6. Confrontare conteggio, fit frequentista, fit bayesiano e selezione ML-assisted in termini di stabilità, incertezza e interpretabilità.

6 Pipeline operativa proposta

La pipeline è pensata come estensione progressiva del notebook esistente, non come sostituzione. Ogni blocco produce output diagnostici e può essere discusso separatamente con il docente.

#	Blocco	Output principale	Responsabile
0	Baseline notebook	Lettura dati, ricostruzione massa, selezione KKK, A_{raw} globale, Dalitz plot	Marco
1	Fit frequentista	Modello massa signal + background, fitted yields	Marco
2	Profile likelihood	A_{raw} da fit simultaneo, confidence interval	Marco
3	Analisi bayesiana	Prior, posterior, MCMC, credible interval, Bayes factor	Giacomo
4	Toy-MC / validazione	Coverage check dei confidence/credible interval, campionando dal modello di massa fittato	Entrambi
5	Modulo ML	Weak label da sidebands, classificatori, ROC, stabilità di A_{raw}, CV/regolarizzazione	Entrambi
6	Comparison	Confrontare A_{raw} baseline, fit, bayes e ML-assisted; cross-check Magnet Up/Down; confronto con valori pubblicati	Entrambi

Table 3: Pipeline operativa con responsabile per blocco.

7 Analisi baseline dal notebook

La baseline riproduce il notebook originale. In questa fase la stima dell'asimmetria è ottenuta principalmente da conteggi dopo preselezione e selezione di massa: riferimento semplice, confrontabile e vicino al materiale ufficiale.

Quantità principali

- Massa invariante del candidato B, ricostruita sommando i quadrimomenti delle tre tracce finali sotto ipotesi di massa K/π.
- Carica del candidato B, ottenuta dalla somma delle cariche delle particelle finali.
- Asimmetria globale $A_{raw} = \dfrac{N(B^-) - N(B^+)}{N(B^-) + N(B^+)}$.
- Dalitz variables $m^2(h_i h_j)$, usate per evidenziare strutture risonanti e possibili asimmetrie locali.
- Mappe binned di asimmetria locale A_i e significatività S_i.

8 Estensione frequentista (responsabile: Marco)

Fit di massa

La prima estensione sostituisce il conteggio in finestra con un fit del picco di massa. Il modello minimale è una miscela di segnale e background:

$$f(m) = N_s\, S(m;\theta_s) + N_b\, B(m;\theta_b)$$

dove S può essere inizialmente una gaussiana o doppia gaussiana e B un esponenziale o un polinomio di basso grado. Si parte da un fit semplice e si aumenta la complessità solo se giustificato dai residui. Il paper di riferimento LHCb (arXiv:2403.19921, si veda Sez. 14) usa un modello più realistico — Gaussiana + due Crystal Ball a media condivisa per il segnale, esponenziale per il fondo combinatorio, ARGUS convoluto con una gaussiana per il fondo da decadimenti parzialmente ricostruiti — utile come riferimento per valutare quanto raffinare il modello.

Fit separato e fit simultaneo

- **Fit separato:** si fittano B^+ e B^- separatamente, ottenendo N_s^+ e N_s^-; poi si calcola A_{raw} dai fitted yields.
- **Fit simultaneo:** si usa una parametrizzazione comune $N_s^+ = N_s(1-A)/2$ e $N_s^- = N_s(1+A)/2$, stimando direttamente A.
- **Nuisance parameters:** massa centrale, risoluzione e parametri di background sono trattati come nuisance e profilati quando si studia A.

Profile likelihood e test $A = 0$

La statistica di profilo è definita come

$$q(A) = -2\log\left[\frac{L(A,\hat{\hat{\theta}})}{L(\hat{A},\hat{\theta})}\right].$$

Sotto condizioni regolari, la forma di $q(A)$ permette di ricavare intervalli di confidenza tramite Wilks. Il valore $A = 0$ fornisce un test naturale dell'ipotesi di assenza di asimmetria grezza.

9 Estensione bayesiana (responsabile: Giacomo)

La riformulazione bayesiana riprende lo stesso modello fisico-statistico del fit, ma considera i parametri come variabili aleatorie. L'obiettivo è confrontare confidence intervals frequentisti e credible intervals bayesiani su A_{raw}.

Modello proposto

Parametri: $\theta = (N_s, N_b, A, \mu, \sigma, \lambda_{bkg})$. Posterior: $p(\theta \mid m, q) \propto p(m, q \mid \theta)\, p(\theta)$, dove q rappresenta la carica del candidato B.

Prior iniziali

- N_s, N_b positivi: prior uniformi larghe o HalfNormal.
- $A \in [-1, 1]$: prior uniforme, eventualmente ristretta in una seconda analisi di robustezza.
- μ vicino alla massa del B: prior gaussiana larga o uniforme in una finestra fisicamente sensata.
- σ positivo: HalfNormal o log-uniform debole.
- Parametri di background: prior larghe ma vincolate a forme normalizzabili.

Output bayesiani

- Posterior marginale di A_{raw}; credible interval 68% e 95%.

- **Diagnostica di convergenza MCMC:** autocorrelation time (`get_autocorr_time` di emcee), acceptance fraction e trace plot delle chain, prima di fidarsi dei campioni per gli output successivi.
- Corner plot dei parametri principali (via **emcee** + **corner**).
- Posterior predictive check della distribuzione di massa.
- Confronto diretto con MLE/profile likelihood.
- **Bayes factor** per il test $A = 0$ vs A libero: argomento esplicito di Week 4 del corso, non altrimenti usato nel progetto — affianca un secondo tipo di test d'ipotesi bayesiano al p-value frequentista.

10 Validazione: toy-MC coverage check (entrambi)

Nota: l'estensione a simulazioni phase-space truth-level per gli altri canali ($K\pi\pi$, πKK, $\pi\pi\pi$), presente in una versione precedente della proposta, è stata abbandonata per contenere lo scope del progetto. Resta solo l'uso del file `PhaseSpaceSimulation.root` (canale KKK) già incluso nel notebook ufficiale per la baseline.

Una volta disponibile il modello di massa fittato (blocchi 1–3), la validazione più utile non richiede nuove simulazioni phase-space: si generano pseudo-dataset campionando direttamente dal modello $f(m)$ fittato (parametric bootstrap), iniettando un valore noto di A (es. $A = 0$), si ripetono fit frequentista e posterior bayesiano su molte repliche, e si verifica che la copertura reale dei confidence/credible interval sia coerente con quella nominale (68%/95%). Questo è l'unico modo rigoroso per sapere se l'approssimazione di Wilks è affidabile su questo dataset, ed è a basso costo implementativo una volta che i fit dei blocchi 1–3 funzionano.

11 Modulo machine learning (entrambi)

Il ML verrà introdotto come strumento ausiliario per migliorare o confrontare la selezione signal/background, non come sostituto del fit fisico. Idea centrale: usare le sidebands di massa per costruire weak label.

Costruzione delle label

- Signal-like: eventi in una finestra attorno al picco di massa del B.
- Background-like: eventi nelle sidebands laterali.
- La massa del candidato B non viene usata come feature di input, per ridurre il rischio di mass sculpting.
- Il classificatore produce uno score $s(x)$ interpretato come probabilità o discriminante signal/background.
- **Class imbalance:** controllare il rapporto tra eventi signal-like e background-like dopo la costruzione delle label ed eventualmente correggere con class weights o resampling — argomento esplicito di Lecture 12–13 ("gestione di dati reali e class imbalance"), rilevante perché le sidebands possono restituire un numero di eventi molto diverso dalla finestra di segnale.

Modelli

- Logistic regression come baseline lineare e interpretabile.
- Random forest o gradient boosting/BDT come modello tabellare forte.

- Feed-forward neural network come estensione coerente con il corso.
- Ensemble o bootstrap per stimare la variabilità del risultato ML.

Validazione

- Split esplicito train/validation/test e tuning via cross-validation per BDT/FFNN, con eventuale analisi PCA/correlazione esplorativa sulle feature cinematiche prima della classificazione.
- Feature importance (o permutation importance) sul BDT/RF, per rendere misurabile il criterio di "interpretabilità" del confronto finale.
- ROC curve e AUC; background rejection vs signal efficiency.
- Controllo della distribuzione di massa dopo taglio sullo score.
- Stabilità di A_{raw} al variare della soglia ML.
- **Calibrazione dello score:** reliability diagram (o Brier score) per verificare che $s(x)$ sia davvero interpretabile come probabilità e non solo come discriminante ordinale — argomento esplicito di Lecture 18 ("tipologie di incertezza nei modelli ML"), altrimenti implicito ma non verificato.
- Confronto fra A_{raw} baseline, A_{raw} da fit e A_{raw} dopo selezione ML-assisted.

Stretch goal (opzionale, se il tempo lo permette): MC Dropout sulla FFNN per un'incertezza epistemica sullo score (Lecture 18) — nessuna modifica architetturale, solo inferenza ripetuta con dropout attivo a predict-time.

12 Dalitz plot e asimmetrie locali

La parte Dalitz non va considerata secondaria. Nei decadimenti a tre corpi le asimmetrie CP possono essere localizzate in regioni specifiche dello spazio delle fasi. Per ogni bin i si definisce

$$A_i = \frac{N_i^- - N_i^+}{N_i^- + N_i^+}, \qquad S_i = \frac{A_i}{\sigma(A_i)},$$

con opportuni controlli statistici quando i conteggi sono bassi. Il campione phase-space KKK già disponibile (`PhaseSpaceSimulation.root`) permette di testare la procedura in assenza di asimmetria vera.

Stretch goal (opzionale, se il tempo lo permette): usare un classificatore o un clustering per definire regioni del Dalitz plot in modo adattivo, invece del binning fisso, e verificare se emergono zone di asimmetria non catturate dal binning manuale.

13 Estensioni esplicite della sezione "Further analyses"

Il notebook ufficiale termina con una sezione di possibili analisi ulteriori: systematic uncertainties, mass sidebands e fitting distributions. Il progetto nasce precisamente da questa sezione finale.

14 Deliverable previsti

- Report finale con descrizione fisica, dataset, metodi, risultati e confronto.
- Notebook o set di notebook modulari con codice riproducibile.

Voce nel notebook	**Estensione proposta**	**Output**
Systematic Uncertainties	Variazione finestre di massa, modelli di background, binning Dalitz, soglia ML; cross-check A_{raw} Magnet Up vs Magnet Down (dati già disponibili)	Tabella di stabilità/sistematica
Using mass sidebands	Sideband subtraction e weak label per ML	Confronto sideband vs fit
Fitting distributions	Fit di massa frequentista e bayesiano	Yield, A_{raw}, CI/credible intervals
Further analyses	Toy-MC coverage check; confronto qualitativo con gli A_{CP} pubblicati (arXiv:2403.19921) per illustrare perché $A_{raw} \neq A_{CP}$	Discussione nel report

Table 4: Mappa di espansione della sezione "Further analyses".

- Grafici: massa invariante, fit, residui/pull, profile likelihood, posterior, corner plot, Bayes factor, Dalitz plot, mappe locali, ROC curve, feature importance.
- Tabella finale con A_{raw} stimata tramite conteggio, fit frequentista, fit bayesiano e analisi ML-assisted, più cross-check Magnet Up/Down.
- Script riproducibile per il toy-MC coverage check (campionamento dal modello di massa fittato).
- Sezione finale di limiti: assenza di detector-level simulation completa, efficienze non corrette, uso di weak labels per ML.

15 Piano di lavoro

16 Rischi e mitigazioni

17 Domande da discutere con il professore

1. L'asimmetria da riportare deve rimanere A_{raw} o si vuole discutere almeno qualitativamente la correzione a CP asymmetry?
2. Quale livello di complessità è appropriato per il modello di massa: gaussiana+esponenziale o forme più realistiche (es. Crystal Ball + ARGUS, come nel paper di riferimento)?
3. La parte bayesiana deve essere centrale o presentata come confronto metodologico?
4. Il ML deve essere usato solo per signal/background o anche per studi sul Dalitz plot?
5. Quanto spazio dare a sistematiche, sidebands e stabilità del risultato?

18 Prossimi passi immediati

- **Marco:** eseguire `LHCb_Open_Data_Project.ipynb` end-to-end per ottenere la baseline (lettura dati, massa invariante, A_{raw} da conteggio, Dalitz plot), poi costruire il modello di massa signal + background con **iminuit**.

Fase	Ore	Attività	Output	Chi
1	6–8	Riproduzione notebook e controllo dati/path	Baseline funzionante	Marco
2	6–8	Massa, selezioni, A_{raw} globale e Dalitz plot	Grafici base	Marco
3	8–10	Fit frequentista e profile likelihood	A_{raw} fit + CI	Marco
4	8–10	Bayesian/MCMC + Bayes factor	Posterior + credible interval	Giacomo
5	4–6	Toy-MC coverage check	Validazione copertura CI/credible interval	Entrambi
6	8–12	ML sideband-based + CV/feature importance	ROC + confronto score cut	Entrambi
7	6–8	Report, rifinitura grafici e discussione	Deliverable finale	Entrambi

Table 5: Piano di lavoro con ore indicative e responsabile.

Rischio	Mitigazione
Fit troppo instabile o modello non adeguato	Partire da un modello minimale; usare range di massa limitato; confrontare modelli solo se giustificato.
Interpretazione errata di A_{raw} come CP asymmetry corretta	Chiamarla esplicitamente A_{raw}; discutere produzione, detector asymmetry ed efficienze come limiti; confrontare con gli A_{CP} pubblicati.
ML introduce bias o mass sculpting	Non usare la massa come feature; controllare massa post-selection; studiare stabilità vs soglia.
Analisi troppo ampia	Definire versione minima: notebook + fit frequentista + confronto con conteggio. Bayes/ML come livelli successivi; niente simulazioni phase-space multicanale (abbandonate).
Le due parti (frequentista/bayesiana) divergono nella preselezione o nel modello di massa	Modulo di lettura dati e parametrizzazione $f(m)$ condivisi fin dall'inizio tra Marco e Giacomo (si veda Sez. 1).

Table 6: Rischi identificati e relative mitigazioni.

- **Giacomo:** definire il modello statistico bayesiano (parametri $\theta = (N_s, N_b, A, \mu, \sigma, \lambda_{bkg})$ e prior) sullo stesso modello di massa concordato con Marco, e preparare il setup **emcee**.

19 Conclusione

La proposta è robusta perché parte da un notebook ufficiale e da dati reali pubblici, ma introduce un chiaro avanzamento metodologico. Il progetto, ora svolto in coppia con compiti

chiaramente divisi ma coordinati su un modello condiviso, permette di mostrare competenze in analisi dati HEP, fit statistici, inferenza bayesiana, simulazione Monte Carlo e machine learning, mantenendo un legame diretto con un problema fisico interpretabile: la misura di differenze materia-antimateria nei decadimenti a tre corpi dei mesoni B carichi.

Riferimenti

1. CERN Open Data, *Matter Antimatter Differences – B meson decays to three hadrons*, record 4900. https://opendata.cern.ch/record/4900
2. CERN Open Data, *Matter Antimatter Differences – Project Notebook*, record 4902. https://opendata.cern.ch/record/4902
3. CERN, *Largest matter-antimatter asymmetry observed*, 18 marzo 2022. https://home.cern/largest-matter-antimatter-asymmetry-observed/
4. L. Falcão on behalf of the LHCb Collaboration, *CP violation measurements in three-body charmless B decays*, CKM2023 proceedings, arXiv:2403.19921 [hep-ex].
5. *Statistics & Machine Learning Course Overview*, documento del corso.
6. `LHCb_Open_Data_Project.ipynb`, notebook ufficiale usato come base operativa.