Proposta di progetto

Estensione frequentista, bayesiana e machine learning di un'analisi LHCb Open Data sui decadimenti a tre corpi dei mesoni B

Giacomo Moretti

Proposta operativa per progetto basato sul corso di Statistics & Machine Learning applicato alla fisica delle alte energie

Idea centrale. Partire dal notebook ufficiale CERN Open Data su differenze materia-antimateria nei decadimenti B^± -> h^± h^+ h^-, riprodurre l'analisi guidata, e trasformarla in un progetto metodologico completo: fit frequentista della massa, stima di A_raw con profile likelihood, riformulazione bayesiana con MCMC, simulazioni phase-space per più canali e modulo ML per signal/background e studi di stabilità.

1. Contesto e motivazione

Il progetto si colloca nell'ambito dell'analisi statistica dei decadimenti adronici a tre corpi dei mesoni B carichi, con particolare attenzione alle differenze fra materia e antimateria. Nei decadimenti B^± -> h^± h^+ h^- lo spazio delle fasi a tre corpi permette non solo una misura globale dell'asimmetria, ma anche uno studio locale tramite Dalitz plot, dove eventuali differenze possono essere concentrate in regioni cinematiche specifiche.

L'obiettivo non e produrre una misura competitiva con una pubblicazione LHCb completa, ma usare dati reali e un notebook pubblico validato come base per un progetto didattico avanzato: riproducibile, statisticamente rigoroso e coerente con il programma del corso.

Research question

Una formulazione sintetica della domanda di progetto e:

> *In che misura fit frequentisti di likelihood, inferenza bayesiana e selezioni assistite da machine learning producono stime consistenti e controllate dell'asimmetria grezza A_raw nei decadimenti B^± -> h^± h^+ h^- di LHCb Open Data?*

2. Argomenti del corso utilizzati

Il progetto e disegnato per usare in modo esplicito i blocchi principali del corso di Statistics & Machine Learning applicato alla HEP: inferenza frequentista, likelihood, covariance, profile likelihood, inferenza bayesiana, MCMC, supervised learning, tree-based methods, neural networks e uncertainty estimation.

Modulo del corso	Strumento	Uso nel progetto
Frequentist inference	Hypothesis testing, p-value, MLE	Fit di massa, stima di yield e test A_raw = 0
Covariance/confidence regions	Hessian, Wilks, profile likelihood	Intervalli di confidenza e profiling

		sui nuisance
Bayesian inference	Prior, posterior, MCMC, credible intervals	Posterior su yield e A_raw
Statistical learning	Classification, bias-variance, regularization	ML signal/background con sidebands
Tree/NN methods	BDT, random forest, FFNN	Confronto fra baseline classiche e rete neurale
Uncertainty in ML	Bootstrap, ensemble, calibration	Stabilita dell'asimmetria al variare del modello e della soglia ML

3. Dataset, notebook di partenza e software

Dataset principale

Il dataset principale e il record CERN Open Data "Matter Antimatter Differences - B meson decays to three hadrons". La pagina del record specifica che i dati sono stati raccolti da LHCb nel 2011 a sqrt(s)=7 TeV, sono stati ricostruiti con il software dell'esperimento, selezionati dal trigger e da una selezione offline, e contengono candidati per decadimenti di un mesone B carico in tre particelle cariche. I file sono ROOT TTree e includono solo le variabili ricostruite piu importanti per svolgere l'analisi. Il record riporta circa 8.55 milioni di eventi, 3 file e 1.0 GiB totali.

Lo stesso record include anche una simulazione semplificata del decadimento B^± -> K^± K^+ K^-, non passata attraverso una simulazione della risposta del detector. Questa informazione e particolarmente importante: il campione e utile come riferimento cinematico phase-space, ma non va trattato come full simulation detector-level.

Notebook di partenza

Il notebook ufficiale "Matter Antimatter Differences - Project Notebook" fornisce una analisi guidata dei dati LHCb, cercando differenze nel comportamento di materia e antimateria nei decadimenti B a tre particelle cariche. Il notebook che ho a disposizione riprende questa struttura: simulazione, ricostruzione della massa invariante, dati reali, preselezione, asimmetria globale, Dalitz plot, asimmetrie locali e una sezione finale di possibili estensioni.

Struttura osservata nel notebook ricevuto

- **Lettura simulazione:** PhaseSpaceSimulation.root e ricostruzione della massa invariante.
- **Lettura dati reali:** B2HHH_MagnetDown.root e B2HHH_MagnetUp.root con preselezione PID/muon veto.
- **Analisi base:** conteggio B^+ / B^- e calcolo di A_raw.
- **Dalitz plot:** masse invarianti a due corpi, ordinamento e binned Dalitz plot.
- **Local asymmetries:** mappe di asimmetria, incertezza statistica e significativita locale.
- **Further analyses:** sistematiche, sidebands e fitting distributions. Questa sezione e il punto naturale in cui estendere il notebook.

Ambiente tecnico

- Python/Jupyter come ambiente principale.
- uproot o ROOT per la lettura dei file ROOT/TTree.
- numpy, pandas, scipy, matplotlib per analisi e visualizzazione.
- iminuit/scipy.optimize per fit frequentisti.

- emcee o PyMC per MCMC bayesiano.
- scikit-learn e, opzionalmente, PyTorch/Keras per ML.

4. Obiettivi scientifici e metodologici

1. Riprodurre e completare il notebook ufficiale LHCb Open Data, mantenendo piena tracciabilita rispetto alla baseline.
2. Passare da una stima per conteggio di A_raw a una stima da fit di massa con segnale e fondo.
3. Implementare una stima frequentista con MLE, covariance matrix, profile likelihood e confidence interval.
4. Riformulare lo stesso problema in modo bayesiano, con posterior su yield e asimmetria e credible intervals.
5. Generare simulazioni phase-space truth-level per altri canali B^± -> h^± h^+ h^- e usarle come riferimento cinematico.
6. Applicare ML in modo controllato per separazione signal/background tramite sidebands, senza usare la massa come feature di input.
7. Confrontare conteggio, fit frequentista, fit bayesiano e selezione ML-assisted in termini di stabilita, incertezza e interpretabilita.

5. Pipeline operativa proposta

La pipeline e pensata per essere implementata come estensione progressiva del notebook esistente, non come sostituzione. Ogni blocco produce output diagnostici e puo essere discusso separatamente con il docente.

Blocco	Output principale
0. Baseline notebook	Riprodurre la lettura dati, la ricostruzione della massa, la selezione KKK, l'asimmetria globale e i Dalitz plot.
1. Fit frequentista	Costruire un modello di massa signal+background per B^+ e B^- e stimare i fitted yields.
2. Profile likelihood	Fittare direttamente A_raw tramite parametrizzazione simultanea e ottenere confidence intervals.
3. Bayesian analysis	Definire prior, likelihood e posterior; campionare con MCMC; confrontare credible intervals con CI frequentisti.
4. Phase-space MC	Generare campioni truth-level per KKK, K pi pi, pi KK e pi pi pi; validare Dalitz boundaries e masse.
5. ML module	Costruire weak labels da signal window/sidebands; addestrare modelli signal/background; applicare score cut e ripetere fit.
6. Comparison	Confrontare A_raw e relative incertezze per baseline, fit, Bayesian e ML-assisted selection.

6. Analisi baseline dal notebook

La baseline riproduce il notebook originale. In questa fase la stima dell'asimmetria e ottenuta principalmente da conteggi dopo preselezione e selezione di massa. Questa baseline e fondamentale per avere un riferimento semplice, confrontabile e vicino al materiale ufficiale.

Quantita principali

- Massa invariante del candidato B ricostruita sommando i quattro-momenti delle tre tracce finali sotto ipotesi di massa K/pi.
- Carica del candidato B, ottenuta dalla somma delle cariche delle particelle finali.
- Asimmetria globale A_raw = (N(B^-) - N(B^+)) / (N(B^-) + N(B^+)).
- Dalitz variables m^2(h_i h_j), usate per evidenziare strutture risonanti e possibili asimmetrie locali.
- Mappe binned di asimmetria locale A_i e significativita S_i.

7. Estensione frequentista

Fit di massa

La prima estensione sostituisce il conteggio in finestra con un fit del picco di massa. Il modello minimale e una miscela di segnale e background:

f(m) = N_s S(m; theta_s) + N_b B(m; theta_b)

dove S puo essere inizialmente una gaussiana o doppia gaussiana e B un esponenziale o un polinomio di basso grado. Si parte da un fit semplice e si aumenta la complessita solo se giustificato dai residui.

Fit separato e fit simultaneo

- **Fit separato:** si fittano B^+ e B^- separatamente, ottenendo N_s^+ e N_s^-; poi si calcola A_raw dai fitted yields.
- **Fit simultaneo:** si usa una parametrizzazione comune N_s^+ = N_s(1-A)/2 e N_s^- = N_s(1+A)/2, stimando direttamente A.
- **Nuisance parameters:** massa centrale, risoluzione e parametri di background sono trattati come nuisance e profilati quando si studia A.

Profile likelihood e test A = 0

La statistica di profilo e definita come q(A) = -2 log[L(A, theta_hat_hat) / L(A_hat, theta_hat)]. Sotto condizioni regolari, la forma di q(A) permette di ricavare intervalli di confidenza tramite Wilks. Il valore A=0 fornisce un test naturale dell'ipotesi di assenza di asimmetria grezza.

8. Estensione bayesiana

La riformulazione bayesiana riprende lo stesso modello fisico-statistico del fit, ma considera i parametri come variabili aleatorie. L'obiettivo e confrontare confidence intervals frequentisti e credible intervals bayesiani su A_raw.

Modello proposto

Parametri: theta = (N_s, N_b, A, mu, sigma, lambda_bkg).

Posterior: p(theta | m, q) proportional to p(m, q | theta) p(theta), dove q rappresenta la carica del candidato B.

Prior iniziali

- N_s, N_b positivi: prior uniformi larghe o HalfNormal.
- A in [-1, 1]: prior uniforme, eventualmente ristretta in una seconda analisi di robustezza.
- mu vicino alla massa del B: prior gaussiana larga o uniforme in una finestra fisicamente sensata.
- sigma positivo: HalfNormal o log-uniform debole.
- parametri di background: prior larghe ma vincolate a forme normalizzabili.

Output bayesiani

- Posterior marginale di A_raw.
- Credible interval 68% e 95%.
- Corner plot dei parametri principali.
- Posterior predictive check della distribuzione di massa.
- Confronto diretto con MLE/profile likelihood.

9. Simulazioni phase-space degli altri canali

Il docente ha suggerito la possibilita di simulare anche altri canali. La proposta e limitare questa estensione a simulazioni truth-level phase-space, non detector-level. Questo rende il lavoro fattibile e metodologicamente utile.

Canali

- B^± -> K^± K^+ K^-: confronto con il file PhaseSpaceSimulation.root gia disponibile.
- B^± -> K^± pi^+ pi^-: estensione naturale con due pioni e un kaone bachelor.
- B^± -> pi^± K^+ K^-: canale complementare utile per confrontare le ipotesi di massa.
- B^± -> pi^± pi^+ pi^-: canale all-pion, utile per Dalitz boundaries differenti.

Uso previsto

- Validazione della ricostruzione del quadrimpulso e della massa invariante.
- Costruzione di Dalitz plot di riferimento senza risonanze.
- Controllo che le mappe di asimmetria locale oscillino statisticamente intorno a zero quando non viene introdotta CP violation.
- Toy studies per testare fit, binning del Dalitz plot e stabilita numerica.
- Eventuale confronto qualitativo con le strutture risonanti presenti nei dati reali.

Punto da chiarire con il docente: confermare che sia sufficiente una simulazione phase-space truth-level, senza risonanze, accettanza, risoluzione o PID response del detector.

10. Modulo machine learning

Il ML verra introdotto come strumento ausiliario per migliorare o confrontare la selezione signal/background, non come sostituto del fit fisico. L'idea piu difendibile e usare le sidebands di massa per costruire weak labels.

Costruzione delle label

- Signal-like: eventi in una finestra attorno al picco di massa del B.
- Background-like: eventi nelle sidebands laterali.
- La massa del candidato B non viene usata come feature di input, per ridurre il rischio di mass sculpting.

- Il classificatore produce uno score s(x) interpretato come probabilita o discriminante signal/background.

Modelli

- Logistic regression come baseline lineare e interpretabile.
- Random forest o gradient boosting/BDT come modello tabellare forte.
- Feed-forward neural network come estensione coerente con il corso.
- Ensemble o bootstrap per stimare la variabilita del risultato ML.

Validazione

- ROC curve e AUC.
- Background rejection vs signal efficiency.
- Controllo della distribuzione di massa dopo taglio sullo score.
- Stabilita di A_raw al variare della soglia ML.
- Confronto fra A_raw baseline, A_raw da fit e A_raw dopo selezione ML-assisted.

11. Dalitz plot e asimmetrie locali

La parte Dalitz non va considerata secondaria. Nei decadimenti a tre corpi le asimmetrie CP possono essere localizzate in regioni specifiche dello spazio delle fasi. Per questo il progetto mantiene e rafforza la parte del notebook dedicata a Dalitz plot e local matter-antimatter differences.

Per ogni bin i si definisce A_i = (N_i^- - N_i^+) / (N_i^- + N_i^+) e una significativita locale S_i = A_i / sigma(A_i), con opportuni controlli statistici quando i conteggi sono bassi. Le simulazioni phase-space permettono di testare la procedura in assenza di asimmetria vera.

12. Estensioni esplicite della sezione "Further analyses"

Il notebook ufficiale termina con una sezione di possibili analisi ulteriori: systematic uncertainties, mass sidebands e fitting distributions. Il progetto proposto nasce precisamente da questa sezione finale. La mappa di espansione e:

Voce nel notebook	Estensione proposta	Output
Systematic Uncertainties	Variazione finestre di massa, modelli di background, binning Dalitz, soglia ML	Tabella di stabilita/sistematica
Using mass sidebands	Sideband subtraction e weak labels per ML	Confronto sideband vs fit
Fitting distributions	Fit di massa frequentista e bayesiano	Yield, A_raw, CI/credible intervals
Further analyses	Phase-space MC per altri canali e confronto globale	Pipeline multicanale

13. Deliverable previsti

- Report finale in PDF con descrizione fisica, dataset, metodi, risultati e confronto.
- Notebook o set di notebook modulari con codice riproducibile.

- Grafici: massa invariante, fit, residui/pull, profile likelihood, posterior, corner plot, Dalitz plot, mappe locali, ROC curve.
- Tabella finale con A_raw stimata tramite conteggio, fit frequentista, fit bayesiano e analisi ML-assisted.
- Campioni phase-space generati o script riproducibile per generarli.
- Sezione finale di limiti: assenza di detector-level simulation completa, efficienze non corrette, uso di weak labels per ML.

14. Piano di lavoro

Fase	Ore indicative	Attivita	Output
1	6-8	Riproduzione notebook e controllo dati/path	Baseline funzionante
2	6-8	Massa, selezioni, A_raw globale e Dalitz plot	Grafici base
3	8-10	Fit frequentista e profile likelihood	A_raw fit + CI
4	8-10	Bayesian/MCMC	Posterior + credible interval
5	6-8	Phase-space MC altri canali	Dalitz reference e validazioni
6	8-12	ML sideband-based	ROC + confronto score cut
7	6-8	Report, rifinitura grafici e discussione	PDF finale

15. Rischi e mitigazioni

Rischio	Mitigazione
Fit troppo instabile o modello non adeguato	Partire da un modello minimale; usare range di massa limitato; confrontare modelli solo se giustificato.
Interpretazione errata di A_raw come CP asymmetry corretta	Chiamarla esplicitamente A_raw; discutere produzione, detector asymmetry ed efficienze come limiti.
ML introduce bias o mass sculpting	Non usare la massa come feature; controllare massa post-selection; studiare stabilita vs soglia.
Simulazione phase-space scambiata per simulazione realistica	Dichiarare truth-level, no detector response, no resonance model, no PID.
Analisi troppo ampia	Definire versione minima: notebook + fit frequentista + confronto con conteggio. Bayes/ML/phase-space come livelli successivi.

16. Domande da discutere con il professore

8. Confermare il canale principale: partire da KKK e poi estendere a K pi pi, pi KK, pi pi pi?
9. Va bene limitare le nuove simulazioni a phase-space truth-level?
10. L'asimmetria da riportare deve rimanere A_raw o si vuole discutere almeno qualitativamente la correzione a CP asymmetry?

11. Quale livello di complessita e appropriato per il modello di massa: gaussiana+esponenziale o forme piu realistiche?
12. La parte bayesiana deve essere centrale o presentata come confronto metodologico?
13. Il ML deve essere usato solo per signal/background o anche per studi sul Dalitz plot?
14. Quanto spazio dare a sistematiche, sidebands e stabilita del risultato?

17. Conclusione

La proposta e robusta perche parte da un notebook ufficiale e da dati reali pubblici, ma introduce un chiaro avanzamento metodologico. Il progetto permette di mostrare competenze in analisi dati HEP, fit statistici, inferenza bayesiana, simulazione Monte Carlo e machine learning, mantenendo un legame diretto con un problema fisico interpretabile: la misura di differenze materia-antimateria nei decadimenti a tre corpi dei mesoni B carichi.

Riferimenti

15. CERN Open Data, Matter Antimatter Differences - B meson decays to three hadrons, record 4900. https://opendata.cern.ch/record/4900
16. CERN Open Data, Matter Antimatter Differences - Project Notebook, record 4902. https://opendata.cern.ch/record/4902
17. CERN, Largest matter-antimatter asymmetry observed, 18 March 2022. https://home.cern/largest-matter-antimatter-asymmetry-observed/
18. Statistics & Machine Learning Course Overview, documento fornito dall'utente.
19. LHCb_Open_Data_Project(2).ipynb, notebook fornito dall'utente come base operativa.