Concetti del report e dei notebook, spiegati

Raw asymmetry in $B^{\pm} \to K^{\pm}K^{+}K^{-}$: σ_B, momento, adeguatezza del modello, $Z = \sqrt{q}$, binning, permutazioni, Brier, silhouette

Giacomo Moretti – appunti di studio

Ottobre 2026

Contents

1 La σ di Barlow (σ_B) **3**

2 Il check dei terzili di momento **4**

3 Adeguatezza del modello: χ^2/ndof, Crystal Ball e posterior predictive check **5**

4 $Z = \sqrt{q}$ e non `norm.ppf(1-p)` **6**

5 Goodness of fit e binning **7**

6 Distribuzione della statistica di omogeneità sotto permutazione delle cariche **8**

7 Il Brier score **9**

8 Il silhouette **10**

9 FIG. XXXVII: il diagramma di affidabilità del Random Forest **11**

10 FIG. XXXVIII: l'incertezza del punteggio **12**

11 FIG. XLII: il campione ad alto fondo **14**

12 Lo *sculpting* della massa da parte del classificatore **15**

13 I pesi di classe deformano le probabilità **17**

14 Il modello lineare: limite del bordo di decisione, non della varianza **18**

15 L'adjusted Rand index **19**

16 L'AUC cross-validato **20**

17 La significance improvement e il taglio al massimo **21**

18 [EXTRA] La correlazione di Spearman **22**

Come leggere questo documento

Nove concetti incontrati nel report e nei notebook (`Code_general/Report/`), seguiti da tre figure dell'appendice sul machine learning (Fig. XXXVII, XXXVIII e XLII, con la numerazione dell'appendice nella versione compilata) e da alcuni concetti di machine learning (sculpting, pesi di classe, limite del modello lineare, ARI, CV AUC), la significance improvement con il taglio al suo massimo e la correlazione di Spearman (extra: non nel corso). Per ciascuno: l'idea, come si calcola, i numeri del progetto, i limiti e la frase per l'orale. I numeri sono quelli del report; dove il notebook usa pochi toy, l'errore statistico è dichiarato.

1 La σ di Barlow (σ_B)

Il problema

Quando una variante dell'analisi cambia il *campione* (per esempio `ProbK>` 0.6 invece di > 0.5) il campione della variante è un sottoinsieme del nominale. Il risultato si sposta di $\Delta = A^{\text{var}} - A^{\text{nom}}$, ma una parte di Δ è solo una fluttuazione statistica (meno candidati, stima diversa). Serve sapere quanto ci si aspetta che Δ fluttui per pura statistica.

Definizione

$$\sigma_B = \sqrt{|\sigma^2_{\text{var}} - \sigma^2_{\text{nom}}|}$$

con σ_{nom} e σ_{var} le incertezze statistiche dei due fit (Hesse, o deviazione standard del posterior).

Perché non la somma in quadratura

I due campioni non sono indipendenti. Lo stimatore del campione completo è quello a varianza minima; per qualunque altro stimatore $\hat{A}'$ dello stesso parametro $\text{Cov}(\hat{A}, \hat{A}') = \text{Var}(\hat{A})$ (altrimenti si potrebbero combinare e fare meglio del minimo). Quindi

$$\text{Var}(\hat{A}' - \hat{A}) = \sigma'^2 + \sigma^2 - 2\sigma^2 = \sigma'^2 - \sigma^2.$$

Come si usa (regola di combinazione)

- Varianti che **cambiano il campione** (finestra, preselezione): contribuisce solo se $|\Delta| > \sigma_B$.
- Varianti che cambiano solo il **modello** sugli stessi dati (fondo, segnale): non c'è fluttuazione statistica attesa, conta tutto lo spostamento, salvo che i dati rifiutino la variante ($\Delta\chi^2 > 25$).
- In ogni gruppo si prende il massimo $|\Delta|$ tra le varianti che contano; i gruppi (indipendenti) si sommano in quadratura.

Numeri

Variante	Δ	σ_B	Esito
`ProbK>` 0.4	-0.0032	0.0037	non conta
`ProbK>` 0.6	$+0.0058$	0.0050	**conta** ($\sim 1.2\,\sigma_B$), domina la sistematica
finestra da 5150	-0.0005	0.0036	non conta (Hesse di quel fit poco accurato)

Verifica con bootstrap su campioni annidati: sd(shift)/mediana(σ_B) $\simeq 1.00$ (run lunga, 200 repliche).

Limiti

σ_B è la differenza di due numeri quasi uguali, quindi sensibile a piccole differenze tra metodi; una variante vicina alla soglia può essere classificata diversamente senza cambiare il risultato. Non fa parte del corso (nei notebook è etichettato `[EXTRA]`); riferimento: R. Barlow, *Systematic errors: facts and fictions*, hep-ex/0207026.

Per l'orale. Per campioni annidati la fluttuazione attesa tra due stime è $\sqrt{\sigma^2_{\text{sub}} - \sigma^2_{\text{full}}}$; uno spostamento più piccolo non è una sistematica, uno più grande sì.

2 Il check dei terzili di momento

Cosa verifica

Le asimmetrie strumentali (rivelazione, produzione) dipendono dalla cinematica: l'efficienza per K^+ e K^- cambia con l'impulso, l'asimmetria di produzione con p_T e rapidità. Un'asimmetria fisica del decadimento non ha motivo di dipendere così dal momento del B. Domanda: A_{raw} cambia al variare del momento del B?

Come si fa

Si calcolano p_T e p del B (somma dei tre impulsi), si divide il campione in tre terzi con lo stesso numero di candidati (6 577 ciascuno), prima in p_T poi in p; in ogni terzo si rifà il fit nominale (12 parametri) e si confronta A con il valore globale -0.0441 ± 0.0085.

Risultato

	terzo 1	terzo 2	terzo 3
p_T	-0.056 ± 0.017	-0.036 ± 0.014	-0.045 ± 0.013
p	-0.039 ± 0.014	-0.048 ± 0.015	-0.048 ± 0.015

Tutti compatibili con il globale entro 1σ; il χ^2 rispetto a un valore costante è, come ordine di grandezza, ~ 0.9 per p_T e ~ 0.2 per p con 2 gradi di libertà: nessuna dipendenza.

Limiti

Un offset *costante* (per esempio una asimmetria di rivelazione uguale a tutti i momenti) non si vede: serve un canale di controllo o le correzioni A_P, A_D dell'analisi pubblicata. Ogni terzo ha $\sim 6\,600$ candidati, quindi una dipendenza debole resta nascosta.

Per l'orale. Ho diviso in terzi di p_T e di p del B, rifatto il fit in ciascuno e verificato che A_{raw} sia compatibile con il valore globale; non c'è una tendenza, ma il test non esclude un offset costante.

3 Adeguatezza del modello: χ^2/ndof, Crystal Ball e posterior predictive check

Frase del report: *il modello non raggiunge* $\chi^2/\text{ndof} \approx 1$ *(164.1/88) perché le code del segnale sono più pesanti di una gaussiana, ma* A_{raw} *cambia di* -0.0002 *con un segnale Crystal Ball; il check predittivo riproduce l'asimmetria in fette di massa (*$p_B = 0.67$*) e mette la differenza dei* χ^2 *delle due cariche ai margini delle repliche (*$p_B = 0.08$*).*

1. $\chi^2/\text{ndof} = 164.1/88$

Il χ^2 confronta, in bin da 10 MeV, i conteggi osservati con quelli del modello fittato. Ci sono 2×50 bin meno 12 parametri: 88 gradi di libertà. Con un modello giusto ci aspettiamo ~ 1; qui ~ 1.9 con $p \sim 10^{-6}$: il modello non è una descrizione perfetta.

2. Perché

La gaussiana è troppo "magra" sui fianchi: il segnale vero ha una coda verso le masse basse. I pull mostrano struttura proprio sui fianchi del picco.

3. Perché non conta

Con una Crystal Ball (nucleo gaussiano più coda a potenza) il χ^2 scende a 131.0/86 e A_{raw} cambia di -0.0002, un centesimo dell'incertezza statistica. Lo spostamento tra segnale e fondo è praticamente uguale per B^+ e B^-; l'asimmetria, rapporto, ne è quasi insensibile.

4. Posterior predictive check

Si estrae un valore dei parametri dal posterior, si simula un intero dataset (replica), si calcola una statistica sui dati e sulla replica; p_B è la frazione di repliche con statistica $\geq$ quella osservata. Non è un p-value frequentista: valori lontani da 0 e da 1 sono buoni.

- **Asimmetria in fette di 50 MeV** ($p_B = 0.67$): statistica non ottimizzata dal fit; il modello predice come l'asimmetria varia lungo la massa e i dati la seguono.
- $\chi^2(B^+) - \chi^2(B^-)$ ($p_B = 0.08$): ai margini; lieve indizio che un segno sia fittato peggio, non significativo.

Per l'orale. Il modello sbaglia un po' la forma del picco (code non gaussiane), ma l'asimmetria non dipende dalla forma: con la Crystal Ball cambia di 0.0002 e il check predittivo mostra che l'asimmetria nelle fette di massa è riprodotta.

4 $Z = \sqrt{q}$ e non `norm.ppf(1-p)`

Il punto

Per il teorema di Wilks, sotto H_0 la statistica di verosimiglianza di profilo $q = -2\ln\lambda$ segue una χ^2_1. Poiché una χ^2_1 è la distribuzione del quadrato di una gaussiana standard, la significatività è $Z = \sqrt{q}$ senza passare dal p-value.

Il legame con il p-value

A può avere entrambi i segni: test a *due code*,

$$p = P(\chi^2_1 > q) = 2\,[1 - \Phi(\sqrt{q})] \quad \Rightarrow \quad \sqrt{q} = \Phi^{-1}\big(1 - \tfrac{p}{2}\big)\,.$$

Conversione ($q(0) = 27.0$, $p = 2.05 \times 10^{-7}$)	Risultato
$\sqrt{q}$	5.20σ
`norm.isf(p/2)` (due code)	5.20σ
`norm.isf(p)` (una coda)	5.07σ

Quindi `norm.ppf(1-p)` dà 5.07 perché conta una sola coda; con $p/2$ si ottiene 5.20. Torna anche con $|\hat{A}|/\sigma_A = 0.0441/0.0085 \approx 5.2$.

Dettaglio numerico

Per Z grandi `norm.ppf(1-p)` perde precisione ($1 - p$ arrotonda a 1): si usa `norm.isf(p/2)` oppure $\sqrt{q}$.

Nota: "χ^2_1 è il quadrato di una gaussiana, sicuro?"

La definizione è esatta: se $Z \sim N(0,1)$ allora $Z^2 \sim \chi^2_1$. Ma q ha la distribuzione χ^2_1 solo *asintoticamente* (Wilks): è uguaglianza in distribuzione, non numerica. Come numero, $q(A_0) = ((\hat{A} - A_0)/\sigma)^2$ vale se la verosimiglianza è esattamente parabolica. Per questo si verifica con toy ($q(0)$ con $A_{\text{true}} = 0$ contro χ^2_1) e il segno di A lo dà $\hat{A}$.

Per l'orale. $Z = \sqrt{q}$ perché $q \sim \chi^2_1$ per Wilks; equivale a `norm.isf(p/2)`, a due code. Con una coda si ottiene 5.07 invece di 5.20.

Perché il conteggio dà 6.1σ e il fit 5.2σ

Il test binomiale esatto di $N^- = N^+$ su tutti i 19 731 candidati ($N^- \approx 10\,292$, $N^+ \approx 9\,439$) ha $A_{\text{count}} = -0.0432 \pm 0.0071$, quindi $|A|\sqrt{N} \approx 6.1$. Il fit ha $\hat{A} = -0.0441 \pm 0.0085$, cioè 5.2σ. I due non sono in tensione perché rispondono a domande diverse:

- il **conteggio** testa l'asimmetria di segnale *e* fondo insieme, senza la massa; non paga il costo di separare il fondo, e per questo ha l'errore più piccolo (0.0071);
- il **fit** testa l'asimmetria del *solo segnale*, con quella del fondo come parametro libero, e per questo ha l'errore più grande (0.0085): i 5.2σ sono il numero che si riferisce al segnale.

I valori centrali sono vicini (-0.0432 e -0.0441) perché l'asimmetria del fondo, $A_b \approx -0.04$, è simile a quella del segnale.

Per l'orale. Il 6.1σ è del conteggio su tutti i candidati e non paga la separazione del fondo; il numero da citare per il segnale è il 5.2σ del fit. Non sono in tensione: misurano due quantità diverse con valori centrali quasi uguali.

5 Goodness of fit e binning

Il problema

Il fit sui dati ha $\chi^2 = 160$ per 88 gradi di libertà ($p \sim 5 \times 10^{-6}$). Ma il p-value vale solo se χ^2 segue davvero la legge χ^2_{88}, cosa non garantita per un χ^2 binnato di un fit non binnato. Voglio sapere quanto χ^2 viene *quando il modello è vero*.

Cosa si fa

1. Si prende il modello adattato ai dati: tutti i parametri (N_s, μ, σ, fondi) e $A = -0.0441$.
2. Si generano molti dataset finti da questo modello (nel report 1000): stesso numero di eventi; il modello è vero per costruzione.
3. Si rifitta ciascuno con la stessa procedura dei dati.
4. Si calcola il χ^2 con due binning: 10 MeV (88 gdl) e 2.5 MeV (388 gdl).
5. Si confronta la distribuzione dei toy con la legge teorica e con il valore dei dati.

I toy non sono generati con asimmetria zero: usano $A_{\text{true}} = -0.0441$ (il fit) solo perché usano il modello adattato intero. Il valore di A non influenza questo test: il χ^2 misura la forma in massa, non la differenza tra i segni.

Risultato

Binning	χ^2 dei dati	p	Significato
10 MeV (88 gdl)	160	5×10^{-6}	5.4σ
2.5 MeV (388 gdl)	–	0.03	2.0σ

I χ^2 dei toy hanno media $\approx$ numero di gdl: il p-value è affidabile. Il disaccordo dei dati si vede di *più* con bin larghi (somma su più eventi) e si diluisce con bin piccoli (pochi eventi per bin).

Cosa causa il misfit

Non è principalmente il fondo: i residui sono sui fianchi del picco; con la Crystal Ball il χ^2 scende da 164 a 131, mentre con una sola esponenziale peggiora molto (298/92), quindi il fondo a due esponenziali è già adeguato. È la forma del segnale (code più pesanti di una gaussiana). Non influenza A_{raw}: -0.0002 con la Crystal Ball.

Per l'orale. Il modello non riproduce perfettamente la forma del picco; il disaccordo si vede con bin da 10 MeV e si diluisce con bin da 2.5 MeV per la poca statistica per bin. Non influenza A_{raw}.

6 Distribuzione della statistica di omogeneità sotto permutazione delle cariche

La statistica

Nella griglia 8×8 del piano di Dalitz, ogni bin i ha asimmetria locale A_i e significatività $S_i = (A_i - A_{\text{glob}})/\sigma(A_i)$. La statistica di omogeneità è

$$\chi^2 = \sum_i S_i^2, \qquad 31 \text{ gradi di libertà (32 bin popolati } - 1).$$

Sui dati vale 80.8. Ipotesi nulla: asimmetria *uniforme*, la stessa A_{glob} ovunque.

Il test di permutazione

1. Si prendono i candidati veri con le loro posizioni nel piano di Dalitz.
2. Si mescolano a caso le etichette di carica tra i candidati: la distribuzione in Dalitz e l'asimmetria globale restano uguali, ma ogni struttura locale è distrutta.
3. Si ricalcola $\chi^2 = \sum S_i^2$ sul campione mescolato; si ripete 2000 volte.

Cosa si legge

- I χ^2 mescolati hanno media ~ 31.5 e sd ~ 8.4: la legge χ^2_{31} (media 31, sd 7.9). La statistica è calibrata.
- Il valore osservato 80.8 sta oltre tutte le 2000 permutazioni (massimo ~ 70): $p < 1/2000 = 5 \times 10^{-4}$.

Se non ci fosse dipendenza dalla posizione, il valore osservato cadrebbe *dentro* la distribuzione mescolata; invece sta lontanissimo, quindi l'asimmetria **non è uniforme**. Il test non dice *dove* né *perché* (lo mostrano mappe, $\phi(1020)$, regione della pubblicazione). Si usa invece della tabella del χ^2 perché alcuni bin hanno pochi eventi e $\sigma(A_i)$ è stimata dai dati: la permutazione costruisce la distribuzione nulla direttamente dai dati.

Per l'orale. Se la carica non dipendesse dalla posizione, mescolarla non cambierebbe nulla. Lo faccio 2000 volte e il valore osservato cade fuori da tutte: $p < 5 \times 10^{-4}$.

7 Il Brier score

Definizione

Errore quadratico medio tra la probabilità predetta e l'esito vero:

$$\mathrm{BS} = \frac{1}{N}\sum_{i=1}^{N}(p_i - y_i)^2, \qquad y_i \in \{0, 1\}.$$

p_i è la probabilità di "signal-like", y_i l'etichetta vera.

Come si legge

- 0 = perfetto; più basso è meglio.
- Un modello "ignorante" che dà sempre $\bar{y}$ ottiene $\bar{y}(1-\bar{y})$: con classi 0.89/0.11 circa 0.10; con classi bilanciate 0.25.
- È una *proper scoring rule*: il minimo si raggiunge dicendo la probabilità vera.

Perché oltre all'AUC

L'**AUC** misura solo il *ranking* (i signal-like hanno punteggio più alto dei background-like?) e non cambia se si moltiplicano i punteggi per 0.3. Il **Brier** misura anche la *calibrazione*: se il modello dice 70%, il 70% di quei candidati è davvero signal-like? I pesi di classe (`balanced`) spostano le probabilità: per il Random Forest il Brier raw è 0.122 e dopo la ricalibrazione isotonica scende a 0.062, con l'AUC invariata (la ricalibrazione è monotona).

Decomposizione

$$\mathrm{BS} = \underbrace{\text{calibrazione}}_{\text{probabilità oneste?}} + \underbrace{\text{raffinatezza}}_{\text{quanto separa i casi}} - \underbrace{\text{incertezza dei dati}}_{\bar{y}(1-\bar{y})}.$$

La ricalibrazione abbassa solo il primo termine.

Per l'orale. L'AUC dice quanto bene ordino i candidati, il Brier quanto sono affidabili le probabilità. I pesi di classe lo peggiorano (0.122) e la ricalibrazione isotonica lo corregge (0.062) senza cambiare l'AUC.

8 Il silhouette

Definizione

Misura quanto sono separati i cluster (K-means) senza usare etichette. Per ogni punto i: $a(i)$ = distanza media dagli altri punti del suo cluster (coesione); $b(i)$ = distanza media dai punti del cluster più vicino a cui non appartiene (separazione).

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \in [-1, 1],$$

e il silhouette del partizionamento è la media su tutti i punti.

Come si legge

s	Significato
vicino a $+1$	cluster ben separati
~ 0	il punto sta sul confine tra due cluster
negativo	probabilmente nel cluster sbagliato

A cosa serve nel progetto

- Serve a scegliere K: l'*inerzia* (somma dei quadrati delle distanze dai centroidi) scende sempre con K e non ha minimo; il silhouette invece ha un massimo. Sul piano di Dalitz il massimo è a $K = 3$ (calcolato su un sottocampione di 4000 punti: è $O(N^2)$).
- Ho usato $K = 8$ *fissato in anticipo*, per confrontare con la griglia 8×8 e per non scegliere K guardando l'asimmetria. Non è l'ottimo del silhouette, e nel report lo dico.

Limiti

Il silhouette tende a preferire pochi cluster compatti e convessi; non dice se i cluster hanno un significato fisico, solo geometrico.

Per l'orale. Per ogni punto confronto la distanza media dal suo cluster con quella dal cluster vicino; la media va da -1 a $+1$. L'ho calcolato per scegliere K, ma ho fissato $K = 8$ a priori per confrontare con la griglia fissa: qui è un controllo, non il criterio di scelta.

9 FIG. XXXVII: il diagramma di affidabilità del Random Forest

Il problema

Il classificatore dà un punteggio $s \in [0, 1]$. Si può leggerlo come una probabilità solo se tra i candidati con punteggio $\approx p$ una frazione p è davvero signal-like. Il *reliability diagram* verifica questa proprietà; il Brier score la riassume in un numero.

Come è costruita

1. Il Random Forest (`balanced`, 200 alberi) dà un punteggio "raw" a ogni candidato del campione di *test*.
2. **Curva grigia (raw)**: i punteggi sono divisi in 10 bin di probabilità predetta; in ciascuno si calcola la frazione osservata di candidati signal-like (`calibration_curve`). Barre d'errore binomiali $\sqrt{p(1-p)/n}$, n = candidati del bin. La diagonale è la calibrazione perfetta.
3. **Curva dorata (isotonic)**: ricalibrazione isotonica (`CalibratedClassifierCV`, 5 fold, funzione monotona punteggio $\to$ probabilità, appresa sul training) applicata al test, poi stessa curva a 10 bin.
4. **Brier** per ciascuna versione sul test: 0.122 (raw), 0.062 (isotonic).
5. **Pannello in basso**: istogrammi del punteggio raw per le due classi, scala logaritmica.

Come si legge

- Curva grigia **sopra** la diagonale: il punteggio *sottostima* la probabilità; per esempio dove il modello dice 0.45 circa l'88% è davvero signal-like.
- Perché: i pesi `balanced` danno al segnale peso ~ 0.56 e al fondo ~ 4.4; il modello vede classi bilanciate e restituisce
$$\tilde{p} = \frac{w_s\, p}{w_s\, p + w_b(1-p)}$$
invece di p. Con $w_s/w_b \approx 0.13$, $\tilde{p} = 0.45$ corrisponde a $p \approx 0.87$.
- Curva dorata vicina alla diagonale: probabilità "oneste". L'AUC non cambia (la mappa è monotona), cambia solo il Brier.
- Istogrammi: i signal-like si accumulano a punteggi alti, i background-like a punteggi bassi; i bin a bassa probabilità hanno pochi candidati, quindi barre d'errore grandi.
- La curva isotonica è a gradini perché la regressione isotonica è costante a tratti: non è un difetto.

Per l'orale. Il punteggio raw è sbilanciato dai pesi di classe; la ricalibrazione isotonica lo corregge (Brier 0.122 $\to$ 0.062) senza cambiare l'ordinamento, quindi l'AUC resta la stessa.

10 FIG. XXXVIII: l'incertezza del punteggio

Il problema

Un punteggio da solo non dice quanto è affidabile: due candidati con $s = 0.5$ possono avere "0.5 ± 0.01" oppure "0.5 ± 0.3". La figura chiede quanto è incerto il punteggio e da cosa dipende.

Teoria: due tipi di incertezza

- **Aleatoria**: dovuta ai dati, irriducibile; le due classi si sovrappongono nelle variabili usate, quindi nemmeno il modello migliore può dire di più.
- **Epistemica**: dovuta al modello, addestrato su un campione finito; *diminuisce con più dati*.

Tre stimatori basati sulla variabilità tra più modelli:

Stimatore	Come si ottiene	Cosa misura
RF trees	scarto standard delle predizioni dei 300 alberi	variabilità del bagging
MC dropout	FFNN con dropout attivo in predizione, 300 passate	varianza di un'approssimazione bayesiana
Deep ensemble	10 FFNN con semi diversi	varianza da inizializzazione e ottimizzazione

Misurano sorgenti diverse: i valori assoluti non sono confrontabili.

Come si legge

- **(a)** Spread degli alberi contro punteggio medio, per classe (banda 16–84%). Forma a *campana*: poco spread agli estremi (alberi concordi), massimo a $s \approx 0.4$–0.5. In parte è una proprietà matematica: per valori in $[0, 1]$ con media s lo scarto non supera $\sqrt{s(1-s)}$. Le due classi cadono sulla stessa curva: l'incertezza dipende dal punteggio, non dal tipo di candidato.
- **(b)** Distribuzione dell'incertezza per candidato: ensemble il più stretto (media ~ 0.05), dropout intermedio (~ 0.095), alberi il più largo (~ 0.18).
- **(c)** Spread degli alberi contro la dimensione del training ($\approx$ 2 500, 5 100, 10 200 candidati): scende da ~ 0.22 a ~ 0.18 per entrambe le classi.

Cosa dice e limiti

- (c) è il test che separa i due tipi: lo spread diminuisce con i dati, quindi una parte è epistemica; ciò che resta a punteggi intermedi è la sovrapposizione delle classi (aleatoria).
- Lo spread degli alberi **non è una barra d'errore calibrata**: dice dove il modello è instabile, non una probabilità con copertura nota. La forma a campana è quasi obbligata; l'informazione nuova sta in (c). La parte aleatoria è dedotta per differenza.

Come si misura lo spread degli alberi

Un candidato è una riga della tabella dei dati: le 20 variabili usate dal classificatore (la massa non c'è). In `X_test` (forma $N \times 20$) ogni riga è un candidato; in `tree_preds` (forma $300 \times N$) ogni colonna è un candidato e ogni riga un albero.

Per ogni candidato:

1. ciascuno dei 300 alberi (addestrati su campioni bootstrap e sottoinsiemi casuali di variabili) lo fa cadere in *una* foglia e restituisce un numero: la frazione (pesata) di signal-like in quella foglia, un valore in $[0, 1]$ e non un voto 0/1;
2. si calcolano media e deviazione standard (`ddof=0`) di quei 300 numeri *sugli alberi*: la media è il punteggio del forest, la deviazione standard è lo spread.

Non sono media e deviazione *delle foglie di un albero*: conta solo la foglia dove cade quel candidato. Esempio con 5 alberi: valori $0.90, 0.80, 0.95, 0.70, 0.85 \rightarrow$ punteggio 0.84, spread 0.087.

```
tree_preds = np.stack([t.predict_proba(X_test)[:, 1] for t in rf.estimators_])  # (300, N)
unc_rf     = tree_preds.std(axis=0)     # spread per candidato
mean_score = tree_preds.mean(axis=0)    # punteggio del forest
```

Attenzione: è la variabilità di un *singolo albero*. L'errore sulla media dei 300 alberi sarebbe spread/$\sqrt{300}$, circa 17 volte più piccolo, ma non è quello che si disegna.

Come si costruiscono i tre pannelli

Si parte dagli array del notebook: `tree_preds`, `unc_rf`, `unc_mc` (MC dropout, 300 passate con `training=True`), `unc_de` (deviazione standard tra 10 reti), `y_test` (etichette deboli).

- **(a)**: i candidati di ciascuna classe si raggruppano in 10 bin di punteggio medio; in ogni bin con almeno 20 candidati si traccia la mediana dello spread e la banda 16–84% (`np.percentile`); due curve, una per classe.
- **(b)**: istogrammi normalizzati (`density=True`) di `unc_rf`, `unc_mc`, `unc_de` sugli stessi bin (0–0.35).
- **(c)**: si *riaddestra* il forest con il 25%, 50% e 100% del training, si ricalcola lo spread sul test e se ne fa la media su tutti i candidati e separatamente per classe.

```
for frac in (0.25, 0.5, 1.0):
    idx  = np.random.choice(len(y_train), int(frac*len(y_train)), replace=False)
    rf_f = RandomForestClassifier(n_estimators=100, max_depth=8, min_samples_leaf=20,
                                  class_weight="balanced").fit(X_train[idx], y_train[idx])
    sp   = np.stack([t.predict_proba(X_test)[:, 1] for t in rf_f.estimators_]).std(axis=0)
    rows.append((len(idx), sp.mean(), sp[y_test==0].mean(), sp[y_test==1].mean()))
```

Il notebook `08` disegna una versione semplificata (scatter per (a), istogrammi per (b), i numeri di (c) solo stampati); la figura a tre pannelli del report viene dall'analisi completa.

Come sono distribuiti i punti

Nello scatter (circa 3 400 candidati, uno per punto) la nuvola segue la campana ma la *densità non è uniforme*:

- si addensa a punteggio alto (0.7–0.9), dove lo spread è piccolo (0.1–0.2): lì cade quasi tutto il campione, perché circa l'88% dei candidati con etichetta è signal-like;
- a punteggi bassi (0–0.3) ci sono pochi punti (i background-like, $\sim 12\%$);
- nel mezzo (0.3–0.6) i punti sono radi, quindi le bande 16–84% di (a) sono più larghe.

Conseguenza: lo spread *medio* del forest (~ 0.18) è dominato dai candidati ad alto punteggio, non da quelli a punteggio intermedio dove lo spread è massimo; la "incertezza media" non descrive la parte del campione dove il classificatore è meno sicuro. Le tre distribuzioni in (b) hanno forme diverse (ensemble stretto a ~ 0.03, dropout con picco a ~ 0.07 e una coda, forest ampia fra 0.1 e 0.3), a conferma che misurano cose diverse.

Per l'orale. L'incertezza del punteggio ha una parte epistemica, che cala con più dati (pannello c), e una aleatoria, la sovrapposizione delle classi, massima per punteggi intermedi. I tre stimatori misurano cose diverse.

11 FIG. XLII: il campione ad alto fondo

Il problema

Nel campione nominale il fondo sotto il picco è poco ($\sim 4\%$ nella finestra di segnale) e il taglio ML non migliora $\sigma(A_{\text{raw}})$. Dove potrebbe aiutare davvero? In un campione con molto più fondo.

Cosa si è fatto

1. Campione più largo: `ProbK`> 0.3 (33 328 candidati; il nominale ne ha 19 731 con > 0.5).
2. Due modi di ripulirlo, confrontati *a parità di efficienza sul segnale*: PID più stretto (`ProbK`$> 0.3 \ldots 0.8$, curva blu) oppure taglio sul punteggio del GBM riaddestrato su questo campione (soglie $0 \ldots 0.9$, curva oro).
3. Per ogni selezione: fit nominale frequentista $\rightarrow A_{\text{raw}}$, $\sigma(A)$, N_s.
4. Efficienza $= N_s/N_s(\texttt{ProbK} > 0.3)$: è *relativa* al campione di partenza, che per costruzione ha efficienza 1. La linea punteggiata è la selezione nominale.

Curva	Taglio	Efficienza
PID (blu)	`ProbK`> 0.3 (campione di partenza); > 0.4; 0.5 (nominale); 0.6; 0.7; 0.8	1.00; 0.86; 0.68; 0.50; 0.32; 0.18
ML (oro)	punteggio > 0 (nessun taglio); > 0.3; 0.5; 0.7; 0.8; 0.9	1.00; 0.98; 0.93; 0.78; 0.59; 0.21

A efficienza 1 non c'è alcun taglio in più: le due curve coincidono (stesso campione, stesso fit).

Come si legge

- **(a)** $\sigma(A_{\text{raw}})$ contro efficienza: cresce al diminuire dell'efficienza (meno eventi). A efficienza alta (> 0.55) la curva oro sta sotto la blu di circa 0.0003–0.0005 (3–6%); a efficienza media il PID è pari o un po' meglio; l'incrocio non è un risultato (sei punti per curva, collegati da rette).
- **(b)** A_{raw} contro efficienza: tutti i punti sono compatibili entro le barre, ma c'è una struttura: il PID stretto riporta A verso il valore nominale (~ -0.044); il taglio ML resta a ~ -0.055, il valore del campione largo, fino a efficienza ~ 0.8.

Cosa dice e limiti

1. Anche con molto più fondo il guadagno del ML sul PID in precisione è modesto.
2. Allargare `ProbK` sposta A (decadimenti mal identificati non descritti dal modello di massa): il PID li toglie, il taglio ML *no*, perché il classificatore è addestrato a separare "sotto il picco" da "bande laterali" (combinatorio) e non conosce quei decadimenti. Coerente con il report.

I campioni sono annidati: i punti sono correlati e le differenze vanno lette come tendenza. La struttura in (b) è compatibile con le barre d'errore: è un indizio, non una significatività.

Per l'orale. Anche con molto più fondo il taglio ML migliora $\sigma(A)$ solo di qualche percento rispetto al PID e non rimuove i decadimenti mal identificati, perché le etichette deboli vengono dalla massa.

12 Lo *sculpting* della massa da parte del classificatore

Che cos'è

Sculpting ("scolpire") è questo: se si taglia sul punteggio di un classificatore e quel punteggio dipende dalla massa, il taglio **deforma lo spettro di massa** dei candidati selezionati: può creare un picco finto nel fondo o scavare un buco nelle bande laterali, anche se nel campione di partenza non c'era.

Perché sarebbe un problema

Il fit di massa distingue segnale e fondo dalla *forma* dello spettro: picco gaussiano contro esponenziali lisce. Se il taglio cambia la forma del fondo in modo non liscio, il modello non la descrive più e sposta eventi tra segnale e fondo; A_{raw} può spostarsi.

Perché poteva succedere qui

Le etichette deboli dicono "signal-like" a chi sta vicino al picco e "background-like" a chi sta nelle bande: il classificatore è addestrato a riconoscere *dove sta in massa* un candidato. Non vede la massa, ma vede i **momenti** dei tre kaoni, e la massa è una funzione dei momenti: potrebbe ricostruirla, e un taglio sul punteggio terrebbe preferenzialmente gli eventi vicino al picco.

Il test

1. Si riaddestra il classificatore *senza le 9 componenti di momento*; restano PID, parametri d'impatto e variabili del B: non ha più modo di ricostruire la massa dai momenti.
2. Si guarda la qualità del fit di massa dopo il taglio. Se fosse sculpting, senza i momenti il χ^2 tornerebbe al valore normale.
3. Risultato (notebook `09`): χ^2 del fit di massa ≈ 160 senza taglio, ≈ 257 con il taglio, ≈ 229 con il taglio di un classificatore senza momenti. Il peggioramento resta, quindi **non è sculpting**: il taglio cambia la *composizione* del fondo (tiene decadimenti parzialmente ricostruiti o mal identificati che il modello non descrive). Nel report (fit bayesiano) il χ^2 passa da 164 a 253.

Il ruolo del χ^2 del vertice e dei parametri d'impatto

Le variabili che pesano di più nel classificatore sono quelle **topologiche**: i χ^2 del parametro d'impatto delle tre tracce (`H*_IPChi2`), la distanza di volo del B e il χ^2 del vertice (`B_VertexChi2`). Sono le cinque più importanti del forest. Contano per due motivi:

- **Non sono funzioni della massa invariante**: dicono se le tre tracce vengono da un vertice spostato dal punto di collisione e di buona qualità, come un B che ha volato prima di decadere, e non da una combinazione casuale. Questo riduce il rischio di sculpting dalla massa.
- **Spiegano perché il ML non toglie i decadimenti mal identificati**: un $B \to K\pi\pi$ mal identificato ha anch'esso un vertice spostato e buono, quindi per queste variabili assomiglia al segnale. Il classificatore separa "vero B" da combinatorio (bande laterali), non "KKK" da "$K\pi\pi$". Coerente con la Fig. XLII e con l'osservazione che il taglio ML non sposta A_{raw} verso il valore del PID stretto.

Limiti

Le variabili topologiche possono comunque essere correlate con la massa in modo indiretto (per esempio per decadimenti parzialmente ricostruiti). Il test senza momenti elimina il canale diretto, non quello indiretto. Il peggioramento del fit dopo il taglio è un fatto sperimentale; la sua interpretazione come cambio di composizione è la più naturale, ma non è dimostrata in modo indipendente.

Per l'orale. Sculpting è quando un taglio su un classificatore deforma lo spettro di massa perché il classificatore ne conosce la massa, per esempio dai momenti. L'ho verificato togliendo i momenti: il peggioramento del fit resta, quindi è un cambio di composizione del fondo. Il classificatore si basa soprattutto su variabili di vertice e parametro d'impatto, che separano i veri B dal combinatorio ma non dai decadimenti mal identificati.

13 I pesi di classe deformano le probabilità

Frase del report: *i pesi di classe deformano le probabilità, che convergono a* $\tilde{p} = w_s p/[w_s p + w_b(1-p)]$ *invece di* p*; una ricalibrazione isotonica su fold held-out la corregge senza cambiare l'ordinamento.*

L'idea

Con pesi di classe la perdita conta ogni campione della classe c con peso w_c. Il minimo della perdita pesata è la probabilità che si avrebbe con proporzioni a priori diverse: le *odds* vengono moltiplicate per i pesi.

Derivazione

Con $p = P(s \mid x)$ e $\text{odds} = p/(1-p)$:

$$\widetilde{\text{odds}} = \frac{w_s}{w_b} \cdot \frac{p}{1-p} \quad \Rightarrow \quad \tilde{p} = \frac{\widetilde{\text{odds}}}{1 + \widetilde{\text{odds}}} = \frac{w_s\, p}{w_s\, p + w_b\,(1-p)}.$$

"Converge" significa che un modello ben addestrato (campione abbastanza grande) tende a $\tilde{p}$, non a p.

Nel progetto

Pesi `balanced` $w_c = N/(2N_c)$; classi 15 130 signal-like e 1 940 background-like (88.6%/11.4%): $w_s \approx 0.56$, $w_b \approx 4.4$, $w_s/w_b \approx 0.13$. Il modello si comporta come se le classi fossero 50/50 e *sottostima* la probabilità di essere signal-like.

p vera	0.2	0.5	0.8	0.9	0.95
$\tilde{p}$ restituita	0.03	0.11	0.34	0.53	0.71

Il punteggio $\tilde{p} = 0.5$ corrisponde a $p \approx 0.89$; in Fig. XXXVII dove il modello dice 0.45 l'88% è davvero signal-like.

Cosa cambia e cosa no

- **Ranking invariato**: $\tilde{p}$ è crescente in p, quindi ordinamento e AUC non cambiano.
- **Soglie e probabilità cambiano**: "punteggio > 0.5" non è "più probabile signal-like che no", ma $p > 0.89$.
- **Inversione**: $p = \dfrac{w_b\,\tilde{p}}{w_b\,\tilde{p} + w_s(1-\tilde{p})}$; la ricalibrazione isotonica lo fa in modo empirico, senza assumere la formula.

Per l'orale. I pesi di classe cambiano le proporzioni a priori viste dal modello: le odds sono moltiplicate per w_s/w_b. Il modello restituisce $\tilde{p}$ invece di p; con pesi 0.56/4.4 lo score 0.5 vale in realtà circa 0.89. L'ordinamento è lo stesso e l'AUC non cambia.

14 Il modello lineare: limite del bordo di decisione, non della varianza

Frase del report: *the limitation of the linear model is its decision boundary, not the variance.*

Le due cause di un modello debole

Causa	Cosa succede	Rimedio
Varianza (overfitting)	il modello si adatta al rumore del training: bene sul training, peggio sul test	regolarizzare, più dati
Bias (underfitting)	il modello non ha la flessibilità per la struttura vera	un modello più flessibile

Ridge e Lasso agiscono sulla *varianza*: riducono i coefficienti.

Cosa mostra la scansione di $C = 1/\alpha$

L'AUC cross-validato è **piatto** su un intervallo largo di C, con massimo ≈ 0.77 (0.7686 nel report) sia per Ridge sia per Lasso; scende solo regolarizzando troppo. Se il problema fosse la varianza, regolarizzare di più farebbe salire l'AUC rispetto a C grande. Non succede: non c'è overfitting da curare.

Perché allora il lineare sta a 0.77 e gli alberi a 0.86

Il bordo di decisione di una logistica lineare è un **iperpiano** $w \cdot x + b = 0$ nelle 20 variabili. Se la separazione vera non è piana, nessun iperpiano la rappresenta bene, per quanto regolarizzato. Gli alberi (partizione a scatole) e la rete (composizioni di non linearità) ammettono bordi non lineari: 0.857–0.864; già un singolo albero superficiale (~ 0.82) batte il lineare.

Controlli

Training contro test (nessun gap grande: niente overfitting); più dati non aiuterebbero il lineare (converge a un iperpiano ottimo); più flessibilità sì (interazioni, trasformazioni come $\log \chi^2$).

Per l'orale. Ridge e Lasso arrivano allo stesso AUC e la curva è piatta in C: non c'è varianza da regolarizzare. Il lineare resta a 0.77 perché un iperpiano non descrive il confine tra signal-like e background-like, a differenza di alberi e rete (0.86): è un limite di bias, non di varianza.

15 L'adjusted Rand index

Cosa misura

Quanto **due partizioni degli stessi punti** sono d'accordo, correggendo per l'accordo casuale; non servono le etichette dei cluster (possono essere permutate). ARI = 1: partizioni identiche (a meno di rinominare); ≈ 0: accordo pari a quello di partizioni casuali; negativo: peggio del caso.

Come si calcola

Si considerano tutte le *coppie* di punti; una coppia è concorde se i due punti stanno insieme in entrambe le partizioni o separati in entrambe. Rand index = frazione di coppie concordi; poi

$$\mathrm{ARI} = \frac{\mathrm{RI} - \mathbb{E}[\mathrm{RI}]}{\max(\mathrm{RI}) - \mathbb{E}[\mathrm{RI}]}.$$

Nel progetto

Il K-means converge a minimi locali dell'inerzia: due run con inizializzazioni diverse possono dare partizioni diverse. L'ARI mostra se la partizione trovata è **stabile**. Nel report ARI > 0.998 ($K = 8$): i cluster sono una proprietà dei dati, non del seme. Nel notebook `09`, con meno inizializzazioni, vale 0.976 (ancora molto stabile).

È un extra?

Sì: fuori dal programma, come il silhouette (nei notebook è marcato `[EXTRA]`). Sono nel corso il K-means, l'inerzia e il gomito; un'alternativa dentro il corso è confrontare inerzia e centroidi tra due semi.

Per l'orale. Il K-means può finire in minimi locali, quindi ho confrontato due run con inizializzazioni diverse con l'adjusted Rand index (extra rispetto al corso): frazione di coppie di punti raggruppate allo stesso modo, corretta per il caso. Qui > 0.998.

16 L'AUC cross-validato

Le due parti

AUC (area under the ROC curve): probabilità che, scelto a caso un candidato signal-like e uno background-like, il modello dia un punteggio *più alto* al signal-like. Vale 0.5 per un modello casuale e 1 per uno perfetto. Misura solo l'ordinamento, non la calibrazione.

Cross-validazione a k fold: serve a stimare la prestazione su dati nuovi *senza toccare il test set*.

1. Si divide il training in k parti uguali (qui $k = 5$), stratificate (stessa proporzione di classi).
2. Si addestra su $k - 1$ fold e si calcola l'AUC sul fold lasciato fuori.
3. Si ripete k volte, ruotando il fold di validazione.
4. Si riportano media e deviazione standard dei k valori, per esempio 0.866 ± 0.016.

A cosa serve nel progetto

- **Scegliere il modello di riferimento**: quello con CV AUC più alto sul training (gradient boosting, 0.866 contro 0.863 del forest), senza guardare il test.
- **Scegliere gli iperparametri**: la scansione di C per Ridge e Lasso e le griglie di forest, boosting e FFNN.
- **Il test AUC resta indipendente**: calcolato una volta sola sul 20% messo da parte, con incertezza bootstrap (~ 0.012).

Cosa significano i numeri

Quantità	Esempio	Cosa dice
CV AUC	0.866 ± 0.016	media su 5 fold; ± 0.016 è la *dispersione tra i fold*, non l'errore sulla media (che sarebbe $0.016/\sqrt{5} \approx 0.007$)
Test AUC	0.864 ± 0.012	prestazione sul campione di test, con errore bootstrap

I due concordano: nessun segno di overfitting nella scelta del modello.

La cautela: winner's curse

Il *massimo* del CV AUC su molte configurazioni è una stima ottimistica: tra tante configurazioni si sceglie anche quella favorita dal rumore. Dalla ricerca degli iperparametri nel report:

Modello	CV AUC (migliore)	Test AUC (migliore)	Test AUC (default)
Random Forest	0.8706	0.8656	0.8604
Gradient Boosting	0.8684	0.8650	0.8643
FFNN (168 configurazioni)	0.8585 (migliore)	0.8606	0.8568

La differenza CV−test del migliore è ~ 0.003–0.005; il guadagno sul default è al più 0.005, meno dell'incertezza del test AUC (0.012): gli iperparametri di default sono adeguati.

Per l'orale. Il CV AUC è l'AUC medio su 5 fold del training: addestro su 4 fold, valuto su uno, ruoto. Lo uso per scegliere modello e iperparametri senza usare il test set; il test AUC è calcolato una volta sola su dati mai visti. Il massimo su molte configurazioni è ottimistico (winner's curse).

17 La significance improvement e il taglio al massimo

Il problema

La curva ROC confronta i classificatori su tutti i tagli insieme, ma in un'analisi interessa quanto un taglio sul punteggio migliora la *significatività*. Nella figura ROC del report il pannello (b) risponde a questo: è la *significance improvement*.

Definizione

Un taglio tiene una frazione ε_S dei candidati signal-like e ε_B dei background-like. La significatività $S/\sqrt{B}$ diventa $\varepsilon_S S/\sqrt{\varepsilon_B B}$, cioè si moltiplica per

$$\mathrm{SIC} = \frac{\varepsilon_S}{\sqrt{\varepsilon_B}}, \qquad \mathrm{SIC} = 1 \text{ (nessun taglio)}.$$

Si disegna SIC in funzione di ε_S: ogni punto è un taglio, e la curva parte da 0 (taglio altissimo), arriva a 1 a $\varepsilon_S = 1$ (nessun taglio) e ha un massimo in mezzo. Si disegna solo per $\varepsilon_B \geq 10^{-3}$: sotto, pochi candidati background-like sopravvivono e il rapporto è rumore.

Come si legge

- L'altezza è il *guadagno* di significatività, la posizione sull'asse x è *quanto segnale si tiene*.
- Gli ensemble (RF, GBM) e la rete arrivano a ~ 1.8: il taglio migliore moltiplica la significatività per 1.8; i modelli lineari a ~ 1.4 e l'albero singolo a ~ 1.6. È lo stesso ordine dell'AUC.
- Sotto $\varepsilon_S \sim 0.2$ la curva scende sotto 1: con le weak label i candidati col punteggio più alto non sono tutti signal-like, e un taglio troppo stretto peggiora.

Il taglio al massimo non è l'ottimo della misura

Per il gradient boosting il massimo è SIC = 1.84 a punteggio 0.73 ($\varepsilon_S = 0.66$, $\varepsilon_B = 0.13$); a 0.5, il taglio nominale, è 1.67. Ma $S/\sqrt{B}$ è la figura di merito per un segnale *piccolo* rispetto al fondo; qui il segnale domina (15 130 signal-like contro 1 940 background-like) e la precisione su A_{raw} segue $S/\sqrt{S+B}$. Con le efficienze del GBM questa vale 0.98 del campione intero a 0.5, 0.73 a 0.8 e 0.40 a 0.9. Infatti dopo il taglio a 0.5 l'errore su A_{raw} passa da 0.0085 a 0.0087: nessun guadagno. In più il massimo di una curva rumorosa, preso sul test set, è ottimistico (winner's curse) ed è piatto tra 0.5 e 0.75.

Perché lo si usa comunque

Il taglio a 0.73 dà un campione più puro e più piccolo (11 658 candidati contro 15 709) e quindi un test di stabilità più severo, non un'ottimizzazione:

Metodo	pieno	score > 0.5	score > 0.73
Bayesiano	-0.0443 ± 0.0085	-0.0451 ± 0.0087	-0.0404 ± 0.0097
Frequentista	-0.0441 ± 0.0085	-0.0447 ± 0.0086	-0.0401 ± 0.0097
Conteggio	-0.0432 ± 0.0071	-0.0446 ± 0.0080	-0.0381 ± 0.0093

Gli spostamenti (+0.004 a +0.005) sono 0.9 volte lo spread atteso tra campioni annidati, e $A \neq 0$ resta a 4.1σ (profilo di verosimiglianza) contro 5.2σ: la precisione peggiora perché si hanno meno candidati.

Per l'orale. La SIC dice di quanto un taglio moltiplica $S/\sqrt{B}$. Il massimo (1.84 a 0.73) non è il taglio ottimo per la misura, perché qui il segnale domina e la precisione segue $S/\sqrt{S+B}$; l'ho usato come test di stabilità più severo, e A_{raw} si sposta meno di un sigma.

18 [EXTRA] La correlazione di Spearman

Il problema

Per confrontare due modi di classificare le feature (importanza Gini della foresta, |coefficiente| del Lasso) i due numeri non hanno la stessa scala né c'è ragione che siano legati linearmente. Interessa solo se *l'ordine* delle variabili è lo stesso.

Definizione

Si sostituisce ogni valore con il suo *rango* (1 = il più grande) e si calcola la correlazione di Pearson dei ranghi:

$$\rho_S = \mathrm{corr}\big(\mathrm{rg}(x), \mathrm{rg}(y)\big) = 1 - \frac{6\sum_i d_i^2}{n(n^2-1)}$$

(d_i: differenza di posto della variabile i nelle due classifiche; la forma a destra vale senza pareggi).

Come si legge

- $+1$: stessa classifica; 0: nessun legame; -1: classifica invertita.
- Invariante per trasformazioni monotone (la scala non conta) e robusta agli outlier.
- Nel progetto $\rho_S = 0.42$ ($p = 0.06$, $n = 20$): i modelli concordano *solo in parte*. Atteso: il Gini misura l'uso in split non lineari, condiviso tra feature correlate; il coefficiente lineare misura l'effetto a parità delle altre. Entrambi mettono le due variabili del B tra le prime cinque.

Limiti

Con 20 feature il p-value è poco informativo: si usa come descrizione, non come test. Non fa parte del corso (non c'è nelle slide né nei notebook): è un'estensione, con riferimento a Spearman (1904).

Per l'orale. È la correlazione di Pearson calcolata sui ranghi: confronta due classifiche senza assumere la stessa scala né la linearità. $\rho = 0.42$ dice che il modello non lineare e quello lineare concordano solo in parte su quali variabili contano.

Il filo comune

- **Distribuzioni nulle**: Wilks ($Z = \sqrt{q}$), toy e permutazioni servono tutti a dire cosa mi aspetto se l'ipotesi è vera.
- **Cosa non va bene**: il modello è imperfetto sulla forma del picco, ma A_{raw} no.
- **Metriche**: l'AUC ordina, il Brier calibra, il silhouette separa i cluster.
- **Probabilità**: i pesi di classe le deformano ($\tilde{p}$), la ricalibrazione le corregge senza cambiare il ranking; il modello lineare è limitato dal bias, non dalla varianza.
- **Validazione**: il CV AUC sceglie il modello senza usare il test; il massimo su molte configurazioni è ottimistico (winner's curse).
- **Stabilità**: l'ARI (extra) mostra che la partizione K-means non dipende dal seme.
- **Sculpting**: un taglio che dipende dalla massa deforma lo spettro; qui il test senza momenti mostra che il peggioramento è un cambio di composizione, e il classificatore si basa su variabili di vertice.
- **Che cosa si ottimizza**: la SIC misura il guadagno di $S/\sqrt{B}$ di un taglio, ma qui il segnale domina e la precisione segue $S/\sqrt{S+B}$: il taglio al massimo (0.73) è un test di stabilità, non l'ottimo.
- **Confronto di classifiche**: Spearman (extra) confronta l'ordine delle feature tra due modelli senza assumere scala né linearità.
- **Incertezze**: aleatoria (irriducibile) ed epistemica (cala con i dati); lo spread tra modelli non è una barra d'errore calibrata.