Domande d'orale sull'intero corso
Statistics and Data Analysis (Week 1–4, L9–L20)

Giacomo Moretti

Ottobre 2026

Come usare questo documento

Sono le domande in stile esame fatte in sessione di studio, con la risposta modello, in ordine di programma. Le sorgenti sono le slide del corso (`Statistics_course/00_Reference/All_slides_merged.pdf`, lezioni Week 1–4 e L9–L20) e Cowan, *Statistical Data Analysis*. Le sezioni sulla Week 1 (probabilità, CLT, lognormale, propagazione degli errori) e sui limiti superiori sono scritte a partire dal programma del corso e da Cowan, perché nelle slide non ci sono: da confrontare con i notebook (`Week1_probability.ipynb`, `Week2_CountingExperiment.ipynb`). Il collegamento al progetto (punto (d) della sezione su unfolding e OmniFold) è da completare dopo aver riletto il report.

Blocco	Lezioni	Temi
1	Week 1	probabilità, PDF/CDF, momenti, CLT, propagazione errori, Monte Carlo
2	Week 2	test di ipotesi, Neyman–Pearson, p-value
3	Week 2–3	stimatori, MLE, informazione di Fisher, MVB
4	Week 3	intervalli di confidenza, Wilks, profile likelihood
5	Week 2–4	limiti superiori, goodness of fit, combinazioni, intervalli credibili
6	Week 4	Bayes, MCMC, Bayes factor
7	L9, L10	bias–varianza, loss come NLL, Ridge/LASSO, CV
8	L10, L11	PCA, K-means, alberi, bagging/boosting
9	L12, L13	reti neurali, backprop, ottimizzatori, sbilanciamento
10	L14, L13	immagini, filtri, preparazione dei dati
11	L14–L16	CNN, RNN/LSTM, GNN
12	L17, L18	autoencoder, VAE, incertezza in ML
13	L19, L20	unfolding, OmniFold, progetto
14	tutto	confronti e domande trabocchetto

1 Probabilità, momenti, CLT, propagazione degli errori e Monte Carlo (Week 1)

Domanda. (a) Quali sono gli assiomi di Kolmogorov? Scrivi la probabilità condizionata, il teorema di Bayes e la legge delle probabilità totali. Un test medico ha sensibilità alta ma la malattia è rara: perché un positivo non implica che sei malato? Cosa cambia tra interpretazione frequentista e bayesiana? (b) Come sono legate PDF e CDF? Come si definisce un quantile? Cosa sono densità congiunte, marginali e condizionate, e quando due variabili sono indipendenti? (c) Definisci valore atteso, varianza, covarianza e coefficiente di correlazione. Indipendenti implica incorrelate? E il contrario? Come si trasforma una PDF sotto un cambio di variabile? (d) Enuncia il teorema del limite centrale e quando non vale. Perché il prodotto di molte variabili positive dà una lognormale? (e) Come si propagano linearmente gli errori? Quando smette di valere? (f) Spiega hit-or-miss, rejection sampling e transformation method. A cosa serve il Monte Carlo in un'analisi?

Risposta.

(a) Assiomi: (1) $P(A) \geq 0$; (2) $P(S) = 1$; (3) se $A \cap B = \emptyset$ allora $P(A \cup B) = P(A) + P(B)$. Ne seguono $P(\bar{A}) = 1 - P(A)$, $P(\emptyset) = 0$, $A \subset B \Rightarrow P(A) \leq P(B)$ e $P(A \cup B) = P(A) + P(B) - P(A \cap B)$. Condizionata: $P(A \mid B) = P(A \cap B)/P(B)$. A e B sono indipendenti se $P(A \cap B) = P(A)P(B)$, e allora $P(A \mid B) = P(A)$. Probabilità totali, con S diviso in sottoinsiemi disgiunti A_i: $P(B) = \sum_i P(B \mid A_i)P(A_i)$. Bayes:

$$P(A \mid B) = \frac{P(B \mid A)P(A)}{\sum_i P(B \mid A_i)P(A_i)}.$$

Test medico: $P(D \mid +) = \dfrac{P(+ \mid D)\pi_D}{P(+ \mid D)\pi_D + P(+ \mid \bar{D})(1 - \pi_D)}$. Se la prevalenza π_D è piccola, anche con sensibilità alta i falsi positivi, che vengono dalla grande popolazione dei sani, possono dominare: il posterior può essere basso. Il teorema di Bayes è valido in qualsiasi interpretazione; cambia il significato del risultato. Frequentista: $P(A) = \lim_{n\to\infty}(\text{volte in cui esce } A)/n$, per esiti di esperimenti ripetibili; le probabilità si associano ai dati, non alle ipotesi (non ha senso $P(\text{supersimmetria})$). Bayesiana (soggettiva): $P(A)$ è il grado di credenza che A sia vera; si può assegnare una probabilità a un'ipotesi, ma serve un prior. Nel test medico: per te "ho il $X\%$ di probabilità di essere malato" (Bayes), per il medico "il $X\%$ di chi risulta positivo è malato" (frequentista). I due approcci rispondono a domande diverse e coincidono con molti dati e prior deboli; la likelihood è il principio unificante.

(b) $F(x) = \int_{-\infty}^{x} f(x')dx'$ e $f = dF/dx$; F è crescente, con $F(-\infty) = 0$ e $F(\infty) = 1$. Il quantile x_α è il valore con $F(x_\alpha) = \alpha$, cioè $x_\alpha = F^{-1}(\alpha)$; la mediana è $x_{0.5}$. Densità congiunta $f(x, y)$; marginale $f_x(x) = \int f(x, y)\, dy$; condizionata $f(y \mid x) = f(x, y)/f_x(x)$. Indipendenza: $f(x, y) = f_x(x)f_y(y)$ (e quindi la likelihood di dati iid è un prodotto).

(c) $E[x] = \int x f(x)dx$; $V[x] = E[(x - \mu)^2] = E[x^2] - \mu^2$; $\text{cov}[x, y] = E[xy] - \mu_x\mu_y$; $\rho = \text{cov}[x, y]/(\sigma_x\sigma_y) \in [-1, 1]$. Indipendenti $\Rightarrow$ incorrelate, ma non il contrario (esempio: x simmetrico e $y = x^2$ hanno correlazione nulla ma sono dipendenti); ρ misura solo la dipendenza lineare. Cambio di variabile $y = y(x)$ monotono: $g(y) = f(x(y))\,|dx/dy|$; in più dimensioni il determinante dello jacobiano. Esempio dal corso: un prior piatto in θ non è piatto in $\lambda = 1/\theta$.

(d) Se $x_1, \ldots, x_n$ sono iid con media μ e varianza finita σ^2, la somma tende a una Gaussiana con media $n\mu$ e varianza $n\sigma^2$; la media campionaria ha varianza σ^2/n. È il motivo per cui gli errori sono spesso gaussiani. Non vale se la varianza è infinita (esempio: la Cauchy, la cui media campionaria non si restringe) o se le variabili sono fortemente correlate; la convergenza è lenta per distribuzioni molto asimmetriche. Lognormale: se $y = \prod_i x_i$ con $x_i > 0$, allora $\ln y = \sum \ln x_i$ è (per il CLT) gaussiano. Quindi y è lognormale: asimmetrica, con coda destra pesante, positiva, con mediana e^μ e media $e^{\mu+\sigma^2/2}$.

(e) Per $y = f(x_1, \ldots, x_n)$ linearizzando attorno ai valori medi:

$$\sigma_y^2 = \sum_{i,j} \frac{\partial f}{\partial x_i} \frac{\partial f}{\partial x_j} V_{ij} = \nabla f^T \, V \, \nabla f,$$

dove V è la matrice di covarianza. Per variabili incorrelate: somma in quadratura dei contributi $(\partial f/\partial x_i)^2 \sigma_i^2$. Per somme si sommano in quadratura gli errori assoluti, per prodotti e rapporti quelli relativi; con le correlazioni il segno del termine misto conta. Vale se f è circa lineare entro l'intervallo di variazione degli x_i (errori piccoli rispetto alla scala di variazione di f). Altrimenti si propaga con il Monte Carlo: si campionano gli x_i, si calcola y e se ne guarda la distribuzione.

(f) Tre metodi per campionare una PDF $f(x)$ a partire da numeri uniformi:

- **Hit-or-miss**: si prende x_i uniforme sul dominio e y_i uniforme in $[0, M]$ con $M \geq \max f$; si tiene x_i solo se $y_i < f(x_i)$.
- **Rejection sampling**: come sopra ma si propone x_i da una PDF $g(x)$ simile a f, con $Mg(x) \geq f(x)$; y_i uniforme in $[0, Mg(x_i)]$, si tiene se $y_i < f(x_i)$. L'efficienza è circa $1/M$.
- **Transformation method**: si impone $r = F(x(r))$, quindi $x(r) = F^{-1}(r)$ con r uniforme in $[0, 1]$. Richiede di integrare f e invertire la CDF.

Un computer usa PRNG (numpy: PCG64; ROOT: TRandom3/Mersenne Twister): algoritmi deterministici, con un seed che garantisce la riproducibilità. Usi del MC: stimare valori attesi e probabilità (frazione di campioni), propagare errori non lineari, simulare esperimenti ripetuti (pseudo-esperimenti), studiare bias e varianza degli stimatori, ottenere la distribuzione delle statistiche di test, calcolare posterior (MCMC), addestrare algoritmi di ML. Distribuzioni di riferimento: Poisson come limite della binomiale (e circa gaussiana per media grande); χ^2_n come somma di n gaussiane standard al quadrato (media n, varianza $2n$); esponenziale per i tempi di decadimento.

Errore tipico all'orale. Dire che incorrelato significa indipendente; applicare il CLT senza varianza finita; confondere media e mediana della lognormale.

2 Test di ipotesi, Neyman–Pearson e p-value (Week 2)

Domanda. Cerchi un segnale: H_0 = solo fondo, H_1 = segnale + fondo, e hai un classificatore con output $t(x)$. (a) Cosa dice il lemma di Neyman–Pearson e perché il rapporto di verosimiglianza è ottimale? (b) Se NP dà già il test migliore, perché si addestrano classificatori ML? (c) Il p-value risulta 0.003: cosa significa e cosa non significa? Come è distribuito sotto H_0? Perché in fisica delle particelle si chiede $Z > 5$?

Risposta.

(a) Per un test di dimensione α fissata, il test con la massima potenza contro H_1 usa la statistica

$$t(x) = \frac{P(x \mid H_1)}{P(x \mid H_0)},$$

con regione critica $t > t_c$ scelto in modo che $P(t > t_c \mid H_0) = \alpha$. Qualsiasi funzione monotona di t (per esempio il logaritmo) dà lo stesso test. Intuizione: si mettono nella regione critica i punti in cui H_1 è più probabile rispetto a H_0; a parità di probabilità spesa sotto H_0 (α) si guadagna la massima probabilità sotto H_1 (la potenza).

(b) NP richiede le PDF multivariate di H_0 e H_1, che di solito non abbiamo. Spesso c'è solo un MC, che dà campioni ma non una formula per $f(x \mid H)$: la simulazione passa per variabili latenti e l'integrale su di esse è intrattabile. Stimare una PDF in alta dimensione è praticamente impossibile

(curse of dimensionality). Un classificatore addestrato con la BCE approssima il rapporto di verosimiglianza: trasforma un problema di stima di densità (difficile) in uno di classificazione (facile). Lo stesso principio rende possibile OmniFold.

(c) Il p-value è la probabilità, assumendo H_0, di osservare dati almeno altrettanto discrepanti da H_0:

$$p = \int_{t_{\text{obs}}}^{\infty} f(t \mid H_0)\, dt.$$

Non è $P(H_0 \mid \text{dati})$: in ambito frequentista $P(H_0)$ non esiste; servirebbe Bayes con un prior. Sotto H_0 il p-value è uniforme in $[0, 1]$; sotto H_1 tende a stare vicino a 0. $p = 0.003$ significa: se H_0 fosse vera, un risultato così estremo capiterebbe lo 0.3% delle volte. In fisica delle particelle si chiede $Z > 5$ ($p \approx 3 \cdot 10^{-7}$) per la look-elsewhere effect (molti test, p-hacking), per sistematiche non previste e per evitare falsi annunci di scoperta.

Errore tipico all'orale. Dimenticare che il p-value dipende implicitamente dall'ipotesi alternativa, che definisce cosa significa "più estremo"; confonderlo con $P(H_0)$.

3 Stimatori, MLE, Fisher e MVB (Week 2–3)

Domanda. (a) Scrivi la likelihood di n misure indipendenti da $f(t; \tau) = \frac{1}{\tau} e^{-t/\tau}$ e ricava l'MLE di τ. (b) L'MLE è sempre non distorto? Che proprietà ha asintoticamente? (c) Come stimi l'incertezza su $\hat{\tau}$ in almeno tre modi? Cosa dice la Minimum Variance Bound e quando l'MLE la raggiunge?

Risposta.

(a) $L(\tau) = \prod_i \frac{1}{\tau} e^{-t_i/\tau}$, quindi $\ln L = -n \ln \tau - \frac{1}{\tau} \sum_i t_i$. Ponendo $\partial \ln L / \partial \tau = 0$ si ottiene $\hat{\tau} = \frac{1}{n} \sum_i t_i$, la media campionaria. Qui è non distorto, con $V[\hat{\tau}] = \tau^2/n$.

(b) No. Esempio: per una Gaussiana lo stimatore $\hat{\sigma}^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$ è distorto; quello non distorto ha $1/(n-1)$. Inoltre l'MLE ha invarianza funzionale (l'MLE di $g(\theta)$ è $g(\hat{\theta})$), e questo di solito rende distorti gli stimatori trasformati. Asintoticamente ($n \to \infty$) è consistente, non distorto, gaussiano ed efficiente (raggiunge la MVB).

(c) Metodi:

- analitico (raramente praticabile);
- MC: pseudo-esperimenti generati con $\hat{\tau}$ al posto del vero τ, ricalcolo di $\hat{\tau}$, deviazione standard;
- bootstrap: ricampionamento con reinserimento; funziona male con pochi dati e con parametri legati alle code;
- seconda derivata: $\sigma^2 = (-\partial^2 \ln L / \partial \theta^2)^{-1}_{\theta=\hat{\theta}}$ (Minuit/Hesse);
- grafico: l'intervallo con $2\Delta\text{NLL} = 1$, che permette errori asimmetrici (Minos).

Information inequality (MVB):

$$V[\hat{\theta}] \;\geq\; \frac{\left(1 + \partial b/\partial\theta\right)^2}{I(\theta)}, \qquad I(\theta) = -E\left[\frac{\partial^2 \ln L}{\partial \theta^2}\right],$$

con b il bias e I l'informazione di Fisher; per stimatori non distorti $V \geq 1/I$. L'MLE raggiunge la MVB asintoticamente; a n finito solo in casi particolari (come questo). In più parametri $V \simeq I^{-1}$: la covarianza è l'inversa della matrice di Fisher.

4 Intervalli di confidenza, Wilks e profile likelihood (Week 3)

Domanda. Hai un parametro di interesse μ (eventi di segnale) e un parametro di disturbo ν (fondo). (a) Perché "il 68% di probabilità che μ sia nell'intervallo" è sbagliato per un intervallo di confidenza? Come si costruisce con la Neyman construction e cosa significa coverage? (b) Cosa dice il teorema di Wilks? Con un POI e 5 parametri di disturbo quanti gradi di libertà ha il χ^2? Quale $2\Delta\text{NLL}$ dà il 68% con 1 e con 2 d.o.f.? (c) Perché il frequentista fa il profiling di ν e il bayesiano marginalizza?

Risposta.

(a) Per un frequentista μ è fisso e fluttua l'intervallo, perché dipende dai dati. Il 68% è la frazione di esperimenti ripetuti i cui intervalli contengono il vero μ (*coverage*). Neyman construction: si scandiscono i valori di μ; per ciascuno si fa un test di ipotesi e si calcola il p-value dei dati osservati; l'intervallo è l'insieme dei μ con $p_\mu \geq \alpha$. Il vero valore è rifiutato con probabilità α, quindi la copertura è $1-\alpha$. La frase giusta per l'intervallo credibile bayesiano è invece "dati questi dati e questo prior, μ sta qui con il 68%".

(b) Con $t_\theta = 2\Delta\text{NLL}(\theta) = -2\ln\big[L(\theta)/L(\hat{\theta})\big]$, nel limite di grandi campioni e con condizioni di regolarità $t_\theta \sim \chi^2_n$, con n il numero di parametri su cui si fa il test. Con un POI e 5 nuisance profilati: $n = 1$ (contano i POI, non i parametri totali). Soglie al 68.3%: $2\Delta\text{NLL} = 1$ con 1 d.o.f. (classico $\Delta \ln L = 0.5$) e 2.30 con 2 d.o.f. Nel goodness of fit, il confronto con il modello saturato dà $\chi^2_{\min}$ con $N - K$ d.o.f.

(c) Il frequentista non ha una PDF dei parametri, quindi non può integrare ν. Usa il profile likelihood ratio

$$\lambda(\mu) = \frac{L(\mu, \hat{\hat{\nu}}(\mu))}{L(\hat{\mu}, \hat{\nu})},$$

ovvero a ogni μ rimassimizza su ν. Il bayesiano integra, $p(\mu \mid x) = \int p(\mu, \nu \mid x)\, d\nu$, senza rapporti né Wilks. La marginalizzazione dipende dal prior su ν e tiene conto del volume dello spazio dei parametri; il profiling no. Con un MCMC la marginale si ottiene ignorando le altre coordinate dei campioni.

5 Limiti superiori, goodness of fit, combinazioni e intervalli credibili (Week 2–4)

Domanda. (a) Una singola misura x_{obs} di una Gaussiana con μ ignoto e σ noto: come calcoli il limite superiore frequentista al livello $1-\alpha$? E quello bayesiano? (b) In un counting experiment con $n \sim \text{Poisson}(s+b)$, come calcoli il p-value di scoperta e la significatività? Come imposti un limite su s? (c) Come si fa un test di goodness of fit con il χ^2? Cosa c'entrano il modello saturato e Wilks? Quando il χ^2 non va bene? (d) Come combini più misure dello stesso parametro? (e) Intervalli credibili: equal-tailed contro HPD. Come si riassume un posterior in un punto?

Risposta.

(a) Frequentista: μ_{up} è il valore ipotetico di μ tale che, sotto quell'ipotesi, la probabilità di osservare $x < x_{\text{obs}}$ è α; quindi $\mu_{\text{up}} = x_{\text{obs}} + \Phi^{-1}(1-\alpha)\,\sigma$ (per il 95%: $x_{\text{obs}} + 1.645\,\sigma$). È l'inversione di un test di ipotesi. Bayesiano: con prior piatto $p(\mu \mid x) \propto L(\mu)$ e il limite al 95% è il quantile 0.95 del posterior; per una Gaussiana illimitata i numeri coincidono con quelli frequentisti, ma il significato è diverso (probabilità su μ contro copertura su esperimenti ripetuti). Con un vincolo fisico $\mu \geq 0$ il bayesiano tronca il prior e il risultato dipende da esso; il frequentista può trovarsi con intervalli vuoti o poco informativi se x_{obs} è molto negativo. (Soluzioni come Feldman–Cousins e CLs sono in Cowan, non nelle slide.)

(b) Sotto H_0 ($s = 0$) il numero atteso è b; il p-value di scoperta è

$$p = P(n \geq n_{\text{obs}} \mid b) = \sum_{n \geq n_{\text{obs}}} \frac{b^n e^{-b}}{n!},$$

e la significatività $Z = \Phi^{-1}(1-p)$ (la scoperta richiede $Z > 5$). Limite superiore su s: il valore s_{up} tale che $P(n \leq n_{\text{obs}} \mid s_{\text{up}} + b) = \alpha$ (stessa logica del punto (a), con una Poisson). La significatività dipende anche da quanto bene è noto b (un parametro di disturbo da profilare o marginalizzare).

(c) Con N misure y_i e modello $f(x;\theta)$ a K parametri, si confronta con il modello saturato ($f_{\text{sat}}(x_i) = y_i$). Con errori gaussiani il rapporto di verosimiglianza diventa

$$t = \sum_{i=1}^{N} \frac{\left(y_i - f(x_i;\hat{\theta})\right)^2}{\sigma_i^2} \equiv \chi^2_{\text{min}}.$$

Per Wilks $t \sim \chi^2_n$ con $n = N - K$ (parametri del saturato meno quelli del modello). Si rifiuta il modello se il p-value $= 1 - F_{\chi^2_n}(t_{\text{obs}})$ è piccolo (regione critica per χ^2 grande); un $\chi^2/n \simeq 1$ è atteso per un buon fit. Il χ^2 presume errori gaussiani; con pochi conteggi per bin vale meglio il rapporto di verosimiglianza di Poisson. Wilks vale nel limite di grandi campioni e con condizioni di regolarità.

(d) La pratica migliore è combinare le likelihood, $\ln L(\theta) = \sum_i \ln L_i(\theta)$, non gli intervalli. Per questo conviene pubblicare la profile likelihood (per esempio su HEPData); se si ha solo l'intervallo, si può ricostruire la likelihood in modo approssimato. Gli esempi del corso sono le medie HFLAV ($R(D)$, $R(D^*)$) e i contorni al 68% con la correlazione ρ e il p-value del χ^2 della combinazione.

(e) Intervallo credibile al livello CL: la regione che contiene il CL del posterior. *Equal-tailed*: lascia la stessa frazione di probabilità nelle due code; *HPD* (Highest Posterior Density): l'insieme dei θ con densità maggiore di una soglia, è l'intervallo più corto, ma dipende dalla parametrizzazione. In più parametri non c'è ordinamento, quindi non si definiscono code uguali: si usa l'HPD. Punto: moda (MAP), mediana o media del posterior, scelta arbitraria che dipende dalla forma; con prior piatto il MAP coincide con l'MLE. Significato: un intervallo credibile al 95% dice "dati questi dati e questo prior c'è il 95% di probabilità che il parametro sia qui"; un intervallo di confidenza dice "il 95% degli intervalli costruiti così in esperimenti ripetuti contiene il vero valore".

6 Bayes, MCMC e Bayes factor (Week 4)

Domanda. (a) Perché $\pi(\theta) = \text{const}$ non rappresenta ignoranza (pensa a $\lambda = 1/\theta$)? Quando MAP = MLE? Cosa è un prior improprio e quando va bene? (b) Descrivi Metropolis–Hastings. Cosa sono burn-in, autocorrelazione e convergenza? Perché serve l'MCMC invece di una griglia? (c) Cos'è un Bayes factor e come si calcola l'evidenza? Perché i prior impropri non vanno bene per il Bayes factor e dove si vede il rasoio di Ockham?

Risposta.

(a) Con $\lambda = 1/\theta$: $\pi(\lambda) = \pi(\theta)\,|d\theta/d\lambda| \propto 1/\lambda^2$, non piatto. Il "piatto" dipende dalla parametrizzazione, e un'ignoranza completa non è ben definita. Prior non informativi sensati riflettono le simmetrie: uniforme per un parametro di traslazione, $1/\theta$ per un parametro di scala (uniforme in $\ln\theta$); altre prescrizioni: Jeffreys, coniugati, massima entropia. Con prior piatto $p(\theta \mid x) \propto L(\theta)$, quindi la moda del posterior (MAP) coincide con l'MLE. Un prior improprio non è normalizzabile; va bene per stimare i parametri finché il posterior è normalizzabile. Va sempre controllata la sensibilità del posterior al prior; se si pubblica la likelihood il risultato resta valido ("se questo prior, allora questo posterior").

(b) Si parte da $\vec{\theta}_0$ e si propone $\vec{\theta}'$ da una distribuzione simmetrica q (per esempio una Gaussiana centrata su $\vec{\theta}_0$). Se $p(\theta') > p(\theta_0)$ si accetta; altrimenti si accetta con probabilità $p(\theta')/p(\theta_0)$ (si

estrae $u \in [0,1]$ e si accetta se $u \le p(\theta')/p(\theta_0)$). Se si rifiuta, si ripete il vecchio punto. Perché serve: una griglia o l'accept–reject scalano esponenzialmente (100 punti $\times$ 5 parametri $= 10^{10}$), l'MCMC campiona soprattutto le regioni ad alta densità e scala circa linearmente. Burn-in: la catena impiega tempo per arrivare nella regione ad alta densità, quindi si scartano i primi passi. Autocorrelazione: punti consecutivi sono correlati, il numero effettivo di campioni è minore di N. Convergenza: la catena può restare intrappolata in un massimo locale; si lanciano più catene da punti diversi. Dal campione si ottengono le marginali dei POI ignorando le altre coordinate, e gli intervalli credibili (equal-tailed o HPD).

(c) Posterior odds = Bayes factor $\times$ prior odds:

$$\frac{P(H_1 \mid x)}{P(H_0 \mid x)} = \frac{P(x \mid H_1)}{P(x \mid H_0)} \cdot \frac{\pi(H_1)}{\pi(H_0)}, \qquad K = \frac{P(x \mid H_1)}{P(x \mid H_0)}$$

(si legge con la scala di Jeffreys). Ogni $P(x \mid H_i)$ è l'evidenza (marginal likelihood):

$$P(x \mid H_i) = \int P(x \mid \theta_i, H_i)\, \pi_i(\theta_i \mid H_i)\, d\theta_i.$$

Con un prior improprio l'integrale non è definito (la costante di normalizzazione è arbitraria, e con essa K). Ockham: un modello con più parametri o più volume di prior diluisce la probabilità e ha un'evidenza minore, quindi è penalizzato se i dati non ne hanno bisogno; la penalità è incorporata nel metodo.

Errore tipico all'orale. Confondere il Bayes factor con un p-value: il p-value non confronta due modelli ed è frequentista.

7 Statistical learning, loss e regolarizzazione (L9, L10)

Domanda. (a) Scrivi la decomposizione dell'MSE di test e spiega cosa succede all'aumentare della flessibilità. Cos'è l'overfitting? (b) Mostra che MSE corrisponde a una likelihood gaussiana e BCE a una di Bernoulli. Perché la BCE è più aggressiva dell'MSE nella classificazione? (c) Differenza tra Ridge e LASSO; perché LASSO azzera i coefficienti? Come si sceglie λ?

Risposta.

(a)

$$E\big[(Y - \hat{f}(x))^2\big] = \mathrm{Bias}[\hat{f}]^2 + \mathrm{Var}[\hat{f}] + \sigma_\epsilon^2.$$

Il bias è l'errore dovuto a un modello troppo semplice; la varianza dice quanto cambia $\hat{f}$ cambiando il training set; σ_ϵ^2 è irriducibile (risoluzione del rivelatore, pile-up). Con più flessibilità il bias scende e la varianza sale: l'MSE di test è a U, quello di training scende sempre. Overfitting: il modello segue il rumore del training (errore di training basso, di test alto, alta varianza); underfitting: alto bias. Parametrici: veloci e interpretabili ma rigidi (rischio di alto bias); non parametrici: flessibili ma richiedono più dati (rischio di alta varianza). Inferenza $\Rightarrow$ interpretabilità, predizione $\Rightarrow$ flessibilità.

(b) Con $y = f(x) + \epsilon$ e ϵ gaussiano, $-\ln L = \text{const} + \sum_i (y_i - f(x_i))^2/(2\sigma^2)$: con σ costante minimizzare l'NLL equivale a minimizzare l'MSE (il fit χ^2 è lo stesso caso). Con $y \in \{0,1\}$ Bernoulli e $p = f(x)$:

$$-\ln L = -\sum_i \big[y_i \ln p_i + (1 - y_i)\ln(1 - p_i)\big] \quad \text{(BCE)}.$$

La BCE è più aggressiva perché $-\ln p$ diverge quando si assegna probabilità ~ 0 alla classe vera, mentre l'MSE è limitato; punisce di più gli errori confidenti. Con Ridge/LASSO in classificazione si usa la regressione logistica con penalità (BCE con sigmoide), non la RSS.

(c) $\mathrm{Loss}_{\mathrm{reg}} = \mathrm{Loss} + \lambda R(\beta)$, con $R = \sum \beta_j^2$ (Ridge) o $\sum |\beta_j|$ (LASSO). Ridge restringe i coefficienti ma non li azzera; LASSO fa feature selection. LASSO conviene con poche feature rilevanti, Ridge

con molte di importanza simile. Forma equivalente: si minimizza la RSS sotto un vincolo, $\sum \beta_j^2 \leq s$ (sfera, liscia) o $\sum |\beta_j| \leq s$ (rombo con gli angoli sugli assi). L'ellisse della RSS tocca il vincolo L1 spesso in un angolo, dove qualche $\beta_j = 0$. Aumentando λ cala la flessibilità: meno varianza, più bias. λ si sceglie con la cross-validation (k-fold: si allena su $k-1$ fold e si valuta sul rimanente, si media, si prende il λ con MSE di test minimo). Prima serve lo standard scaler (media 0, σ 1), altrimenti la penalità colpisce di più le feature con unità piccole.

8 PCA, clustering, alberi, bagging e boosting (L10, L11)

Domanda. (a) Come si definisce la prima componente principale? Relazione con SVD e autovalori; come scegli quante PC tenere? Differenza PCA/LASSO? (b) Descrivi l'algoritmo di Lloyd per il K-means e cosa può andare storto. (c) Come cresce un albero? Perché Gini/entropia e non l'errore 0/1? Cos'è il pruning? Bagging contro boosting: quale riduce varianza e quale bias?

Risposta.

(a) La prima PC φ_1 (con $\|\varphi_1\| = 1$) è la direzione lungo cui la varianza dei dati centrati è massima; equivale alla retta che minimizza la distanza quadratica dai punti. Le successive hanno la stessa definizione ma sono ortogonali alle precedenti. Si ottengono dalla SVD $X = U\Sigma\Phi^T$: le colonne di Φ sono le PC, quelle di $U\Sigma$ gli score; equivalentemente sono gli autovettori di X^TX (la covarianza), con varianza lungo la PC pari all'autovalore. La varianza totale si conserva; $\text{PVE}_m = \lambda_m / \sum \lambda$, e si tengono le PC fino a una frazione sufficiente della varianza (scree plot). La PCA è non supervisionata e non usa il target: tiene le direzioni di massima varianza, non quelle utili per predire Y. LASSO è supervisionato e seleziona feature originali; la PCA combina tutte le feature in nuove direzioni. Va fatta dopo lo scaling. Autoencoder: la PCA trova un iperpiano, l'AE una varietà non lineare.

(b) Si assegna a ogni punto un'etichetta a caso, poi si itera: (1) calcola il centroide di ogni cluster, (2) riassegna ogni punto al centroide più vicino, fino a stabilità. Minimizza la dissimilarità intra-cluster $W(C_\ell)$. Termina sempre ma può fermarsi in un minimo locale (si lancia con più inizializzazioni). K va fissato a priori e dipende dall'applicazione; vanno controllate robustezza (sottocampioni, altri algoritmi) e scaling (senza scaling le variabili con varianza maggiore dominano la distanza euclidea). Ogni punto va in un solo cluster.

(c) Alberi: partizioni binarie ricorsive del feature space in rettangoli (tagli allineati agli assi), modelli non lineari e molto interpretabili. Crescita greedy: a ogni nodo si scandiscono tutte le feature e tutti i valori di taglio, si sceglie quello che minimizza l'impurità pesata dei figli. Non c'è lookahead, quindi si perde l'ottimo globale. Impurità: Gini $= \sum p(1-p)$ o entropia (information gain). L'errore 0/1 è discontinuo e degenere (un taglio utile può non migliorarlo subito); Gini ed entropia sono continue e sensibili ai miglioramenti parziali. Crescere fino a nodi puri è overfitting: si usano stopping (profondità massima, dimensione minima, minima riduzione di impurità) con CV, oppure il pruning a costo-complessità, errore $+ \alpha \cdot$ (#nodi), con α scelto in CV. Regressione: loss MSE, predizione della foglia = media dei y, si sceglie il taglio che minimizza la varianza. **Bagging** (bootstrap + media o voto): riduce la varianza di modelli a basso bias (alberi profondi). **Boosting**: modelli molto regolarizzati addestrati in sequenza, con più peso agli esempi sbagliati; riduce il bias di modelli a bassa varianza (AdaBoost, gradient boosting, XGBoost; parametri: learning rate, numero di alberi, subsample). ROC: TPR contro FPR al variare della soglia; l'AUC la riassume.

9 Reti neurali, backpropagation e ottimizzazione (L12, L13)

Domanda. (a) Cosa calcola un neurone, perché servono non linearità? Cosa dice e cosa non dice l'approssimazione universale? Attivazioni per hidden e output. (b) Discesa del gradiente, SGD con

mini-batch, backprop, vanishing gradient, batch normalization. (c) Momentum, RMSProp, Adam; dropout, early stopping, data augmentation; dataset sbilanciato.

Risposta.

(a) Un neurone calcola $a = \sigma(w \cdot x + b)$. Senza non linearità una composizione di strati lineari resta lineare; con la non linearità si imparano relazioni tra le feature (esempio XOR). Approssimazione universale: una rete con uno strato nascosto, finito e con attivazione non lineare, approssima qualunque funzione continua su un compatto. Non dice quanti neuroni servono né come trovare i pesi: tutta la pratica del deep learning è questo. Perché la profondità: servono meno parametri, le sottofeature si riutilizzano, la sovraparametrizzazione sembra rendere la loss più liscia. Hidden: ReLU (non satura, nessun vanishing gradient per $x > 0$); la sigmoide è poco usata (gradiente piccolo, output non centrato). Output: lineare per la regressione, sigmoide per la binaria, softmax per la multiclasse mutuamente esclusiva (somma 1). Loss: MSE, BCE, cross-entropy categorica.

(b) $w \leftarrow w - \eta \nabla_w L(w)$. GD usa tutto il dataset a ogni passo (troppo costoso); SGD un esempio, mini-batch un piccolo gruppo (8–32): il gradiente è stimatore non distorto di quello vero, con rumore utile, e sfrutta GPU e parallelismo. Backprop: la regola della catena $\partial L/\partial w = \partial L/\partial \hat{y} \cdot \partial \hat{y}/\partial a \cdot \partial a/\partial w$ propagata all'indietro strato per strato; dice "quanta colpa" ha ogni peso nell'errore. Vanishing gradient: il prodotto di molte derivate piccole (sigmoide: massimo 0.25) fa svanire il gradiente, i primi strati non imparano. Rimedi: ReLU, inizializzazione, normalizzazione, skip connections. Batch normalization: normalizza le attivazioni per mini-batch e stabilizza l'addestramento (motivazione originale: internal covariate shift). La loss è non convessa: dipende dall'inizializzazione, ha minimi locali e selle (frequenti in alta dimensione); i minimi piatti generalizzano meglio di quelli stretti. Il learning rate annealing aiuta.

(c) Momentum: accumula una velocità, smorza le oscillazioni nelle direzioni ad alta curvatura e accelera dove il gradiente è costante; aiuta con le selle. **AdaGrad/RMSProp**: learning rate per parametro, scalato con la somma (AdaGrad) o la media mobile (RMSProp) dei gradienti al quadrato. **Adam**: momentum (primo momento m_t) + scala adattiva (secondo momento v_t), con correzione del bias iniziale; $\beta_1 = 0.9$, $\beta_2 = 0.999$, $\epsilon = 10^{-8}$. **Dropout**: spegne a caso una frazione dei neuroni in training, impedisce di affidarsi a poche feature. **Early stopping**: ci si ferma quando la loss di validazione smette di scendere. **Noise injection**: rumore su input o etichette. **Data augmentation**: trasformazioni che preservano la fisica. Dataset sbilanciato: oversampling della minoranza (rischio overfitting); undersampling della maggioranza (si perde informazione); SMOTE (punti sintetici per interpolazione tra vicini della minoranza: meno overfitting, possibile bias); class weights (downsampling + upweighting, così il modello impara sia le feature sia la vera distribuzione delle classi). Preprocessing: standard scaler, e min-max spesso per le reti.

10 Immagini, filtri e preparazione dei dati (L14, L10, L13)

Domanda. (a) Cos'è un'immagine digitale e cosa mostra un istogramma? Che differenza c'è tra operazioni puntuali e filtri? Che cosa fanno thresholding, power law ed equalizzazione? (b) Cos'è una convoluzione, perché è importante e come si gestiscono i bordi? Cosa fanno i filtri di smoothing e quelli derivativi? (c) "Garbage in, garbage out": quali problemi hanno i dati reali e come si prepara un dataset? Standard scaler contro min-max; learning curve e iperparametri.

Risposta.

(a) Un'immagine è una matrice 2D di intensità (livelli di grigio 0–255, oppure 3 canali RGB, quindi larghezza×altezza×3). La digitalizzazione è un'approssimazione della scena reale (risoluzione spaziale e livelli di intensità). L'istogramma conta quante volte compare ogni intensità: mostra luminosità, contrasto, esposizione e dynamic range; la cumulata serve per l'equalizzazione. **Operazioni puntuali**: la nuova intensità dipende solo da quella vecchia e dalla funzione di mappatura, non dalla posizione né dai vicini. Esempi: *thresholding* (da grigio a binario), *power law* (comprime

o espande intervalli scuri o chiari, mettendo in evidenza dettagli diversi), *equalizzazione* (rende l'istogramma il più uniforme possibile, usando tutto il range dinamico). **Filtri**: combinano il pixel con i suoi vicini (dimensione, forma e pesi della finestra; lineari o non lineari).

(b) Un filtro lineare e invariante per traslazione è una convoluzione (teorema): ogni pixel diventa la somma pesata del suo intorno con il kernel. Bordi: crop, pad, extend, wrap. Smoothing: la media su una finestra (blurring) o il filtro gaussiano, con pesi maggiori al centro e normalizzazione preservata; σ è la larghezza. Edge detection: i bordi sono salti di luminosità, individuabili dalla derivata prima; in discreto si usa un kernel centrato e simmetrico come $[-0.5, 0, 0.5]$. Una CNN usa gli stessi filtri ma li impara dai dati, invece di fissarli a mano.

(c) La qualità dell'output dipende da quella dell'input. Tipici problemi: dati inaccurati, mancanti, distorti (non rappresentativi), rumorosi, outlier. Rimedi: data cleaning, feature engineering, validazione; è spesso la parte che richiede più tempo. **Standard scaler**: media 0 e σ 1 per ogni feature; evita che una feature domini solo per le unità e aiuta la convergenza. **Min-max**: comprime in un intervallo, di solito $[0, 1]$, spesso preferito per le reti. Lo scaler va adattato solo sul training set e poi applicato a validazione e test, per non far entrare informazione dal test nel training. Learning curve: l'errore di training e di validazione in funzione delle epoche; il plateau dipende da dimensione del training set, architettura e inizializzazione; se l'errore di validazione risale c'è overfitting. Gli iperparametri non si apprendono con la discesa del gradiente ma con euristiche (prove manuali, grid search, random search, AutoML), valutate su un set di validazione; il test set si usa una sola volta alla fine. Il lavoro standard: baseline semplice (modello lineare) per riferimento, poi BDT, poi rete, confrontando con la stessa metrica.

11 CNN, RNN/LSTM e GNN (L14–L16)

Domanda. (a) Perché una FFNN su immagini non scala? Le due assunzioni di una CNN? Dimensione dell'output di una convoluzione. Cosa fa il pooling? (b) Perché le RNN hanno vanishing/exploding gradient e perché la tanh? Gate di un LSTM e perché la cell state aiuta. Windowing e forecasting ricorsivo contro diretto. (c) Rappresentazione di un grafo, message passing, invarianza/equivarianza, over-smoothing.

Risposta.

(a) Una FFNN appiattisce l'immagine e perde le relazioni spaziali: con 64×64 e 500 nodi nascosti servono ~ 2 milioni di pesi (il triplo con il colore). Assunzioni della CNN: **località** (pattern vicini contano di più) e **invarianza per traslazione** (stessi pesi in ogni posizione). I filtri sono appresi, i parametri calano molto, le operazioni si parallelizzano sulla GPU. Output: $o = \left\lfloor \dfrac{n + 2p - m}{s} \right\rfloor + 1$ (n input, m kernel, p padding, s stride); il padding "same" mantiene la dimensione. Con più canali (RGB) ogni canale ha il suo filtro e i risultati si sommano; si aumenta il numero di filtri negli strati successivi. Pooling (max o average): riduce la dimensione, introduce invarianza locale, riduce l'overfitting. Per immagini sparse (jet) si usano filtri più grandi (es. 11×11). Dropout e data augmentation valgono come per le DNN.

(b) Una RNN legge la sequenza e aggiorna uno stato $h_t = \tanh(Wh_{t-1} + Ux_t + b)$ con pesi condivisi nel tempo; accetta sequenze di lunghezza variabile. La backpropagation through time moltiplica molte derivate: piccole $\Rightarrow$ il gradiente svanisce; pesi grandi $\Rightarrow$ esplode. La tanh è preferita: output in $[-1, 1]$ (può sommare e sottrarre informazione), centrata in zero, derivata massima 1 (contro 0.25 della sigmoide); ReLU farebbe esplodere i gradienti. Per dipendenze lunghe una RNN semplice sovrascrive la memoria e il gradiente va a zero. **LSTM**: cell state C_t; forget gate (0 dimentica, 1 mantiene); input gate (cosa aggiornare e candidati nuovi); aggiornamento $C_t = f \cdot C_{t-1} + i \cdot \tilde{C}_t$; output gate (cosa mandare fuori). Grazie alla somma il gradiente scorre all'indietro senza svanire facilmente. Windowing: la finestra di input ha una larghezza, un offset rispetto alla label e un insieme di feature. `return_sequences=True` dà un output per passo (per impilare LSTM), `False`

solo l'ultimo. Servono stazionarietà (debole: media, varianza e autocorrelazione costanti), feature engineering (angoli del vento, orario) e una baseline semplice (ripetere l'ultimo valore). Ricorsivo: la predizione diventa input (rischio di feedback e bias); diretto: si predice direttamente l'orizzonte voluto.

(c) Un grafo è $G = (V, E)$ con matrice di adiacenza A ($|V| \times |V|$, simmetrica se non orientato), matrice X delle feature dei nodi ($|V| \times D$) e, opzionalmente, delle feature degli archi. A^m conta i cammini di lunghezza m. Message passing: **aggregazione** (somma degli embedding dei vicini) e **aggiornamento** (trasformazione lineare del nodo e del messaggio, poi attivazione non lineare). Dopo K strati ogni nodo contiene informazione sul suo intorno. Compiti: classificazione di grafo (global pooling, ad esempio media, poi MLP), di nodo, di arco (link prediction). Invarianza: l'ordine dei nodi è arbitrario, quindi $f(PV) = f(V)$ per l'output di grafo; l'output di nodo è equivariante: $f(PV, PAP^T) = Pf(V, A)$. Così la rete impara relazioni, non posizioni nella lista. Bias induttivo relazionale: favorisce le soluzioni coerenti con la struttura (se sbagliato può essere troppo restrittivo). Batching: grafi di dimensioni diverse come componenti disgiunte di un unico grafo grande, con pooling per grafo. **Over-smoothing**: dopo troppe iterazioni gli embedding convergono allo stesso valore. Si scelgono gli strati vicino al diametro del grafo e si usano skip connection o MLP profondi per il passaggio dei messaggi. Tipici HEP: jet tagging, tracking (classificazione degli archi); vantaggio: dati sparsi e irregolari, senza griglia.

12 Autoencoder, VAE e incertezza in ML (L17, L18)

Domanda. (a) Come funziona un autoencoder e in cosa differisce dalla PCA? Anomaly detection e denoising; perché serve il collo di bottiglia? (b) Prior, likelihood e posterior variazionale in un VAE; ELBO e i suoi termini; reparametrization trick; cosa succede con KL = 0? (c) Incertezza aleatorica ed epistemica; bagging, deep ensemble, MC dropout, Bayes by Backprop; perché una rete (μ, σ) cattura solo l'aleatorica?

Risposta.

(a) Una FFNN con input e output della stessa forma: encoder → collo di bottiglia → decoder, che minimizza l'errore di ricostruzione (MSE). È addestramento self-supervised: nessuna etichetta. Rispetto alla PCA impara una varietà non lineare a bassa dimensione, la PCA un iperpiano; in entrambi i casi si riduce la dimensione. Il collo di bottiglia (undercomplete) obbliga a comprimere; senza, la rete impara l'identità e non estrae nulla. Anomaly detection: si addestra solo sul fondo, che ricostruisce bene (MSE basso); un evento anomalo, come un possibile segnale, ricostruisce male (MSE alto). È una classificazione a una classe. Denoising: input corrotto (rumore o mascheramento), target pulito; l'AE impara le feature rilevanti e scarta il rumore.

(b) L'encoder produce una distribuzione $q_\phi(z \mid x)$ (μ e σ); il decoder è $p_\theta(x \mid z)$ (likelihood); il prior $p(z)$ è tipicamente $\mathcal{N}(0, I)$. Il posterior vero $p(z \mid x)$ è intrattabile (richiede l'integrale su z) e si approssima con q_ϕ minimizzando la KL.

$$\text{ELBO} = E_q\big[\ln p_\theta(x \mid z)\big] - \text{KL}\big(q_\phi(z \mid x) \,\|\, p(z)\big); \qquad \text{loss} = -\text{ELBO}.$$

Il primo termine è la ricostruzione (accuratezza fisica); il secondo regolarizza lo spazio latente verso il prior (continuo e regolare). Massimizzare l'ELBO equivale a massimizzare un limite inferiore dell'evidenza $\ln p(x)$: si trasforma un integrale in un problema di ottimizzazione. Reparametrization trick: $z = \mu + \sigma\epsilon$ con $\epsilon \sim \mathcal{N}(0, 1)$; il campionamento diventa deterministico rispetto ai parametri e il gradiente passa (non si può derivare un nodo casuale). Con KL = 0 (o $\epsilon = 0$) si torna a un AE deterministico, senza vincolo sul posterior. Dopo l'addestramento il decoder è un generatore: si campiona $z \sim \mathcal{N}(0, I)$ e si ottengono eventi nuovi. Lo spazio latente regolare è interpretabile; la distanza dal centro del prior serve per le anomalie. Banda di incertezza: si campiona da $\mathcal{N}(\mu, \sigma)$ per ogni input e si passano i campioni nel decoder.

(c) Aleatorica: rumore intrinseco nelle osservazioni (omoschedastica se costante, eteroschedastica se dipende dall'input); non si riduce con più dati. **Epistemica**: ignoranza sui parametri del modello; si riduce con più dati ed è cruciale fuori distribuzione (open set recognition: una softmax assegna comunque un'alta probabilità). **Bagging**: M reti su bootstrap; la media è la predizione, la varianza tra le reti è l'incertezza epistemica. **Deep ensemble**: stessa architettura, inizializzazioni diverse, stesso dataset; semplice e parallelizzabile, ma costoso. **Rete** (μ, σ^2) con NLL gaussiana: cattura il rumore dei dati (aleatorica); è deterministica e non segnala di essere fuori distribuzione, quindi manca l'epistemica. Versione più flessibile: quantile regression. **MC dropout**: dropout attivo anche in test e T passaggi; equivale a un'inferenza variazionale approssimata (Gal), la varianza tra i passaggi misura l'ignoranza. **Bayes by Backprop**: ogni peso è una distribuzione $\mathcal{N}(\mu_i, \sigma_i)$ (parametri μ_i, ρ_i: 2× i parametri), con reparametrization trick; la loss è l'ELBO (likelihood + KL con il prior, costo di complessità). Con più dati la likelihood domina sul prior. Più sensibile agli iperparametri. VAE contro BNN: stesso motore (ELBO e reparametrization); il VAE è stocastico solo nel collo di bottiglia (incertezza nella rappresentazione, generazione), la BNN in tutti i pesi (incertezza del modello).

13 Unfolding e OmniFold (L19, L20)

Domanda. (a) Equazione di folding discreta; cos'è R e cosa dice la somma per colonna? Perché invertire R è mal posto? Cosa dice la covarianza tra bin vicine? (b) Confronta inversione di matrice, bin-by-bin, Tikhonov e IBU di D'Agostini. Cos'è il forward folding? (c) Come funziona OmniFold? Trucco del classificatore, le due fasi di reweighting, perché è unbinned e multidimensionale; perché la curse of dimensionality uccide l'IBU?

Risposta.

(a) Il numero atteso di eventi misurati nella bin i è $\mu_i = \sum_j R_{ij}\nu_j + \beta_i$, con ν i veri conteggi per bin e β il fondo. $R_{ij} = P(\text{misurato in } i \mid \text{generato in } j)$ si costruisce con l'MC (risoluzione, accettanza, efficienza); la somma su i per una colonna j dà l'efficienza ε_j. L'inversione $\hat{\nu} = R^{-1}(n-\beta)$ è l'MLE: azzera la distanza tra il modello ripiegato e i dati, quindi è un overfitting analitico (N punti, N parametri) con varianza enorme a bin piccole. È un problema mal posto: R smussa i dettagli fini e R^{-1} li ricrea dalle fluttuazioni statistiche, trattandole come segnale; piccole variazioni dei dati danno grandi variazioni del risultato. La covarianza $V = R^{-1}V_n(R^{-1})^T$ mostra anticorrelazione tra bin adiacenti (una fluttuazione in una va sottratta ai vicini per conservare il totale). Bin larghe rispetto alla risoluzione: stabile ma con bias; bin piccole: poco bias ma instabile. È il bias–varianza di nuovo. R dipende dalla distribuzione vera usata nell'MC: il bias è nullo se la distribuzione è piatta dentro la bin.

(b) Bin-by-bin: fattore moltiplicativo per bin $C_i = \nu_i^{\mathrm{MC}}/\mu_i^{\mathrm{MC}}$; ipotizza migrazioni trascurabili (R diagonale, purity > 70–80%) e forma dell'MC corretta; va bene con bin larghe e per un primo sguardo. **Tikhonov**: massimizza $\ln L(\nu) + \tau S(\nu)$, con S che penalizza la curvatura ($k = 2$) o la pendenza ($k = 1$); τ controlla il compromesso bias–varianza. È un prior sulla regolarità: la smoothness deve essere informazione che hai davvero. **IBU**: Bayes sulle cause C_j e gli effetti E_i,

$$P(C_j \mid E_i) = \frac{P(E_i \mid C_j)P(C_j)}{\sum_k P(E_i \mid C_k)P(C_k)},$$

ogni evento misurato in i è riassegnato alla bin vera j con quel peso, dividendo per l'efficienza. Il prior è la distribuzione vera che si cerca (argomento circolare), risolto iterando: si parte da P_0 (MC o piatto), si normalizza la stima in nuovo prior e si ripete. Poche iterazioni: domina il prior (bias); troppe: si dimentica il prior e crescono le fluttuazioni (varianza); lo stop anticipato è la regolarizzazione (tipicamente 3–6 iterazioni). **Forward folding**: si confronta la teoria ripiegata con i dati (fit χ^2 o likelihood), senza invertire nulla; spesso è la scelta migliore ("Don't unfold").

(c) Con molte variabili la matrice di risposta ha dimensioni enormi (5+5 variabili con 20 bin ciascuna: $\sim 10^{13}$ bin), quindi l'IBU non scala. **Trucco**: un classificatore binario addestrato con BCE per distinguere campioni da $p(x)$ e $q(x)$ dà $f/(1-f) = p/q$, il rapporto di verosimiglianza: da stima di densità (difficile) a classificazione (facile). I pesi sono $w(x) = p(x)/q(x)$. **Iterazione**:

1. reweighting della simulazione a livello reco verso i dati reali (primo classificatore);
2. i pesi si riportano sugli eventi a livello pre-detector (pull-back);
3. un secondo classificatore, tra eventi pre-detector e pre-detector ripesati, dà nuovi pesi (smoothing);
4. si ripete; alla fine gli eventi del generatore ripesati sono la stima.

Il risultato è unbinned, event-based, likelihood-free e multidimensionale: sfrutta tutte le correlazioni e si possono unfoldare molte osservabili insieme. Assunzione: la simulazione deve modellare bene la risposta del detector. In sostanza OmniFold è l'IBU unbinned, multidimensionale e basato su reti neurali.

(d) Progetto *(da completare)*: dove hai usato idee del corso nello studio di ACP su LHCb open data (likelihood fit, profile likelihood, classificatori, incertezze), e quali assunzioni e punti deboli ti aspetti che ti contestino. Questa risposta va scritta dopo aver riletto il report.

14 Confronti e domande trabocchetto

Domande brevi, in cui si cade spesso. Rispondi prima di leggere la risposta.

"Il p-value è la probabilità che H_0 sia vera?"
No. È $P(\text{dati almeno così estremi} \mid H_0)$. $P(H_0 \mid \text{dati})$ richiede un prior (Bayes).

"Un intervallo di confidenza al 68% contiene μ con il 68% di probabilità?"
Per un frequentista no: μ è fisso, l'intervallo fluttua; il 68% è la coverage su esperimenti ripetuti. Quella frase vale per l'intervallo credibile.

"Prior piatto = ignoranza?"
No, dipende dalla parametrizzazione ($\lambda = 1/\theta$ dà $1/\lambda^2$); servono prior che riflettano le simmetrie.

"L'MLE è non distorto?"
Non in generale ($\hat{\sigma}^2$ con $1/n$); lo è solo asintoticamente. L'MLE trasformato (invarianza funzionale) è spesso distorto.

Perché Wilks può non valere?
Pochi dati, parametri al bordo dello spazio fisico (esempio $\mu \geq 0$), likelihood non regolare: 2ΔNLL non segue un χ^2 e va usato un MC (pseudo-esperimenti).

Profiling contro marginalizzazione?
Profiling: massimizza su ν per ogni μ (frequentista, non dipende dal prior). Marginalizzazione: integra su ν con il suo prior (bayesiano, tiene conto del volume).

Se NP è ottimo, perché il ML?
Perché le PDF non si conoscono in alta dimensione; il classificatore ottimo approssima il rapporto di verosimiglianza. È anche la base di OmniFold.

Perché MSE e BCE?
Sono NLL: MSE da rumore gaussiano, BCE da una Bernoulli. La loss è la likelihood cambiata di segno.

Ridge contro LASSO?
L2 riduce, L1 azzera (angoli del vincolo). Ridge se molte feature contano, LASSO se ne bastano poche.

Bagging contro boosting?
Bagging: riduce la varianza di modelli profondi (basso bias). Boosting: riduce il bias di modelli deboli e regolarizzati.

Alto AUC e buon classificatore?
L'AUC non dice nulla sulla calibrazione né sul punto di lavoro; con classi sbilanciate l'accuratezza inganna. Contano soglia, TPR/FPR, significance e il confronto con una baseline.

Validazione o test?
La validazione serve a scegliere iperparametri, il test a stimare l'errore finale e si usa una volta.

PCA contro AE contro VAE?
PCA: lineare, analitica (SVD), massima varianza. AE: non lineare, minimizza l'errore di ricostruzione. VAE: AE probabilistico con prior sul latente (KL) e ELBO, quindi generativo e con spazio regolare.

Ensemble contro MC dropout contro Bayes by Backprop?
Ensemble: M addestramenti, frequentista, costoso. MC dropout: un solo addestramento, equivalente a un'inferenza variazionale approssimata. BBB: pesi come distribuzioni con ELBO, $2\times$ parametri e più sensibile agli iperparametri.

CNN contro GNN?
La CNN opera su una griglia regolare (invarianza per traslazione); la GNN su grafi irregolari e sparsi (invarianza per permutazioni dei nodi). Una convoluzione su immagine è un caso particolare di message passing.

Perché l'IBU non scala e OmniFold sì?
L'IBU bina in d dimensioni (la matrice cresce come $(\text{bin})^{2d}$); OmniFold usa classificatori che lavorano direttamente sui singoli eventi (unbinned).

Unfolding o forward folding?
Il forward folding (ripiegare la teoria e confrontare con i dati) è più semplice e senza bias da regolarizzazione; l'unfolding serve per confrontare esperimenti diversi e con teorie future.

Perché la regolarizzazione nell'unfolding introduce bias?
Perché aggiunge un'informazione (smoothness) che stai assumendo; deve essere informazione vera.

Frequentista contro bayesiano in una frase?
Frequentista: i dati sono casuali, il parametro è fisso (probabilità = frequenza). Bayesiano: il dato è fisso, il parametro è una variabile casuale (probabilità = credenza), con prior. Coincidono con molti dati e prior deboli; la likelihood è comune.